


Mô hình đào tạo không thiên vị để phát hiện hình ảnh tổng hợp hơn do AI tạo ra

Fabrizio Guillaro¹ Giada Zingarini¹ Ben Usman² Avneesh Sud²
Davide Cozzolino¹ Luisa Verdoliva¹

¹Đại học Federico II của Naples ²Google DeepMind



Hình 1. Chúng tôi giới thiệu một mô hình đào tạo mới để phát hiện hình ảnh do AI tạo ra. Để tránh những sai lệch có thể xảy ra, chúng tôi tạo ra các hình ảnh tổng hợp từ quá trình tái tạo tự điều chỉnh của hình ảnh thực và bao gồm cả tính năng tăng cường dưới dạng phiên bản không được sơn. Điều này cho phép tránh những thành kiến về mặt ngữ nghĩa. Kết quả là, chúng tôi có được khả năng khái quát hóa tốt hơn cho các mô hình chưa được nhìn thấy và hiệu chuẩn tốt hơn so với các phương pháp SoTA.


Tóm tắt

Các máy dò pháp y thành công có thể tạo ra kết quả xuất sắc trong các tiêu chuẩn học tập có giám sát nhưng lại gặp khó khăn trong việc chuyển sang các ứng dụng trong thế giới thực. Chúng tôi tin rằng hạn chế này phần lớn là do chất lượng dữ liệu đào tạo không đầy đủ. Trong khi hầu hết các nghiên cứu tập trung vào phát triển các thuật toán mới thì việc lựa chọn dữ liệu huấn luyện lại ít được chú ý hơn, mặc dù có bằng chứng cho thấy hiệu suất có thể bị ảnh hưởng mạnh mẽ bởi các mối tương quan giả như nội dung, định dạng hoặc độ phân giải. Một máy dò pháp y được thiết kế tốt sẽ phát hiện các thành phần tạo tác cụ thể của trình tạo thay vì phản ánh các sai lệch dữ liệu. Để đạt được mục đích này, chúng tôi đề xuất B-Free, một mô hình đào tạo không thiên vị, trong đó hình ảnh giả được tạo ra từ hình ảnh thật bằng cách sử dụng quy trình điều hòa của các mô hình khuếch tán ổn định. Điều này đảm bảo sự liên kết về mặt ngữ nghĩa giữa hình ảnh thật và hình ảnh giả, cho phép bắt kỳ sự khác biệt nào chỉ xuất phát từ các tạo phẩm tinh vi được tạo ra bởi thể hệ AI. Thông qua tính năng tăng cường dựa trên nội dung, chúng tôi cho thấy những cải tiến đáng kể về cả tính khái quát hóa và độ mạnh mẽ so với các máy dò hiện đại và kết quả được hiệu chỉnh nhiều hơn trên 27 mô hình tạo khác nhau, bao gồm cả các bản phát hành gần đây, như FLUX và Stable Diffusion 3.5. Những phát hiện của chúng tôi nhấn mạnh tầm quan trọng của việc thiết kế tập dữ liệu cẩn thận, nhấn mạnh sự cần thiết phải nghiên cứu sâu hơn về chủ đề này. Mã và dữ liệu được cung cấp công khai tại <https://grip-unina.github.io/B-Free/>.

1. Giới thiệu

Sự trỗi dậy của AI tổng hợp đã cách mạng hóa việc tạo ra nội dung tổng hợp, cho phép dễ dàng sản xuất các phương tiện truyền thông tinh vi chất lượng cao, ngay cả đối với những cá nhân không có chuyên môn kỹ thuật sâu. Nhờ giao diện thân thiện với người dùng và các mô hình được đào tạo trước, người dùng có thể tạo nội dung tổng hợp như văn bản, hình ảnh, nhạc và video thông qua các đầu vào hoặc lời nhắc đơn giản [54]. Khả năng tiếp cận này đã dân chủ hóa việc tạo nội dung, cho phép các chuyên gia trong các lĩnh vực như thiết kế, tiếp thị và giải trí tận dụng AI cho mục đích sáng tạo. Tuy nhiên, điều này làm dấy lên mối lo ngại về khả năng sử dụng sai mục đích, chẳng hạn như tạo ra các nội dung giả mạo, thông tin sai lệch và những thách thức liên quan đến sở hữu trí tuệ và tính xác thực của nội dung [4, 17, 27].

Những thách thức chính đối với các trình phát hiện hình ảnh GenAI hiện tại bao gồm tính khái quát hóa - phát hiện các bộ tạo tổng hợp không có trong tập huấn luyện - và đảm bảo tính mạnh mẽ chống lại các khiếm khuyết hình ảnh do chia sẻ trực tuyến, chẳng hạn như nén, thay đổi kích thước và cắt xén [44]. Trong bối cảnh này, các mô hình ngôn ngữ thị giác được đào tạo trước lớn như CLIP [37] đã chứng tỏ khả năng phục hồi ấn tượng trước những thay đổi phân phối này [33]. Sự thành công của các mô hình này trong các ứng dụng pháp y cho thấy rằng việc đào tạo trước trên các bộ dữ liệu lớn và đa dạng có thể là một con đường đầy hứa hẹn phía trước. Một khía cạnh quan trọng thường bị bỏ qua trong tài liệu hiện tại là việc lựa chọn các bộ dữ liệu tốt để huấn luyện hoặc tinh chỉnh các mô hình sao cho



Hình 2. Máy dò pháp y có thể biểu hiện các hành vi trái ngược nhau tùy thuộc vào tập dữ liệu huấn luyện của chúng. Bốn sơ đồ hiển thị phân phối dự đoán cho ba máy dò dựa trên ViT, UnivFD [33], FatFormer [29] và RINE [22], và máy dò được đề xuất. Hình ảnh giả (SD-XL hoặc DALL-E 3) được tạo từ hình ảnh của một tập dữ liệu duy nhất (RAISE ở trên, COCO ở dưới cùng) và chỉ được thử nghiệm với hình ảnh thật của cùng một tập dữ liệu (Synthbuster [2] và tập dữ liệu thử nghiệm từ [11]). Chúng tôi nhận thấy rằng đối với cùng một máy dò (ví dụ: RINE) và cùng một trình tạo ảnh giả (ví dụ: DALL-E 3), mức phân bố điểm có thể khác nhau đáng kể tùy thuộc vào tập dữ liệu được sử dụng, từ thực (bên trái đường chấm) đến giả (bên phải đường chấm) hoặc ngược lại. Điều này có thể là do sự hiện diện của các sai lệch trong tập huấn luyện ảnh hưởng lớn đến dự đoán của máy dò. Mặt khác, máy dò của chúng tôi cho thấy kết quả nhất quán và chính xác.

chủ yếu dựa vào các chữ ký ẩn, không xác định của các mô hình tổng quát [32, 50]. Thật vậy, điều quan trọng là phải đảm bảo rằng các quyết định của máy dò thực sự dựa trên các tạo tác cụ thể của thể hệ chứ không dựa trên các sai lệch dữ liệu có thể có [7, 30, 45]. Trên thực tế, các bộ dữ liệu được sử dụng trong giai đoạn huấn luyện và thử nghiệm của bộ phân loại pháp lý có thể bị ảnh hưởng bởi các kiểu phân cực khác nhau.


Các vấn đề về định dạng đã trở thành gót chân Achilles của các máy dò pháp y ít nhất kể từ năm 2013, khi [5] nhận ra rằng tập dữ liệu để phát hiện giả mạo hình ảnh [14] bao gồm các hình ảnh giả mạo và nguyên sơ được nén bằng các yếu tố chất lượng JPEG khác nhau. Do đó, một bộ phân loại được đào tạo để phân biệt các hình ảnh nguyên gốc và giả mạo có thể tìm hiểu lịch sử xử lý khác nhau của chúng. Vấn đề này đã được nhấn mạnh trong [19] khi tham khảo các bộ dữ liệu hình ảnh tổng hợp và hình ảnh thực. Trên thực tế, cái trước thường được tạo ở định dạng lossless (PNG), trong khi cái sau thường được nén ở định dạng lossless như JPEG. Một lần nữa, bộ phân loại có thể học về sự không nhất quán trong mã hóa thay vì các manh mối pháp lý. Tương tự như vậy, nó có thể học cách lấy mẫu lại các tạo phẩm, như đã được trình bày gần đây trong [38] - trong trường hợp này, một sai lệch đã được đưa ra bằng cách thay đổi kích thước tất cả các hình ảnh thực từ tập dữ liệu LAION về cùng độ phân giải, trong khi vẫn giữ nguyên các hình ảnh giả.

Các manh mối pháp y rất tinh vi và thường không thể nhận thấy bằng mắt người, khiến dễ dàng đưa ra những sai lệch khi xây dựng tập huấn luyện và kiểm tra cũng như quy trình đánh giá. Bản thân nội dung ngữ nghĩa cũng có thể là nguồn gốc của sự thiên vị. Vì lý do này, một số đề xuất gần đây [2, 3, 11] rất cẩn thận khi đưa các cặp hình ảnh thật và giả được đặc trưng bởi cùng một lời nhắc khi xây dựng tập dữ liệu huấn luyện hoặc kiểm tra. Để hiểu rõ hơn về các vấn đề trên, trong Hình 2, chúng tôi trình bày hiệu suất của ba phương pháp tiếp cận dựa trên SoTA ViT [22, 29, 33] trong việc phân biệt hình ảnh thật với hình ảnh giả do SD-XL và DALL-E 3 tạo ra.

Phương pháp này chúng tôi xem xét hai cài đặt: trong trường hợp đầu tiên, hình ảnh thật đến từ tập dữ liệu RAISE [12] và hình ảnh giả được tạo ra bắt đầu từ hình ảnh của cùng một tập dữ liệu. Trường hợp thứ hai sử dụng COCO làm nguồn số thực thay vì RAISE. Chúng tôi lưu ý rằng hành vi không nhất quán của các trình phát hiện pháp lý SOTA trên cùng một trình tạo tổng hợp có thể xảy ra do sự hiện diện của các sai lệch trong quá trình đào tạo. FakeInversion [7] đề xuất một cách tiếp cận hiệu quả hướng tới việc căn chỉnh ngữ nghĩa của dữ liệu huấn luyện bằng cách sử dụng tìm kiếm hình ảnh ngược để tìm các giá trị thực phù hợp, nhưng không thể nắm bắt được phân phối hình ảnh thực sau năm 2021.

Để giảm thiểu những sai lệch tiềm ẩn về dữ liệu, trong công việc này, chúng tôi đề xuất một mô hình đào tạo mới, B-Free, trong đó các hình ảnh tổng hợp được tạo ra bằng cách sử dụng các bản tái tạo tự điều chỉnh của hình ảnh thực và kết hợp các biến thể tăng cường, không được vẽ. Cách tiếp cận này giúp ngăn chặn sự thiên vị về ngữ nghĩa và khả năng sai lệch tiềm ẩn trong các định dạng mã hóa. Hơn nữa, mô hình tránh được các hoạt động thay đổi kích thước có thể đặc biệt có hại bằng cách loại bỏ các manh mối pháp lý cấp thấp tinh vi [18]. Nhìn chung, chúng tôi có những đóng góp sau:

- Chúng tôi đề xuất một tập dữ liệu đào tạo lớn được quản lý gồm 51k hình ảnh thật và 309k hình ảnh giả. Hình ảnh thật có nguồn gốc từ COCO, trong khi hình ảnh tổng hợp là thể hệ tự điều hòa sử dụng Khuếch tán ổn định 2.1. Điều này giúp máy dò tập trung vào các thành phần liên quan đến quá trình tạo tổng hợp, tránh các sai lệch liên quan đến nội dung và mã hóa.
- Chúng tôi cho thấy rằng việc kết hợp tính năng tăng cường dựa trên nội dung phù hợp sẽ mang lại kết quả được hiệu chỉnh tốt hơn. Điều này đảm bảo rằng hiệu suất trong phòng thí nghiệm phù hợp chặt chẽ hơn với hiệu suất mong đợi trên các hình ảnh trong thế giới thực được chia sẻ trên mạng xã hội.
- Chúng tôi nghiên cứu tác động của các thay đổi phân phối khác nhau và chỉ ra rằng bằng cách tận dụng mô hình lớn đã được đào tạo trước, được tinh chỉnh từ đầu đến cuối trên tập dữ liệu của mình, chúng tôi đạt được độ chính xác SoTA vượt trội tới 90% ngay cả trên các máy phát điện không nhìn thấy được.



Hình 3. Tổng quan về các chiến lược hiện có (a, b, c) và đề xuất (d) để xây dựng tập dữ liệu huấn luyện phù hợp. Một số phương pháp cố gắng ghép hình ảnh tổng hợp với hình ảnh thực tương ứng bằng cách sử dụng cách tạo hình ảnh dựa trên lớp (a) hoặc tạo văn bản thành hình ảnh với mô tả của hình ảnh thực (b). Trong (c) hình ảnh thật được đưa đến bộ mã hóa tự động để tạo ra hình ảnh giả được tái tạo có cùng nội dung. Khác với (c), theo cách tiếp cận của chúng tôi, một bản giả mạo tự điều chỉnh được tạo ra bằng cách sử dụng các bước phổ biến (d) và chúng tôi cũng thêm một bước tăng cường nội dung.

2. Công việc liên quan

Một tập huấn luyện được quản lý tốt có tầm quan trọng sống còn đối với bất kỳ phương pháp dựa trên dữ liệu nào. Trong những năm gần đây, nhận thức này cũng đã tăng lên nhiều trong lĩnh vực pháp y và đã có nhiều nỗ lực theo hướng này theo hai hướng công việc chính: i) hình thành một tập dữ liệu đáng tin cậy bằng cách lựa chọn cẩn thận các giả mạo “tự nhiên”, hoặc ii) tạo ra một tập dữ liệu tổng hợp hoàn toàn bằng cách đưa các tạo tác pháp y vào hình ảnh thực.

Lựa chọn dữ liệu đào tạo tự nhiên tốt. Bài báo của Wang và cộng sự [46] là một trong những bài báo đầu tiên chứng minh tầm quan trọng của việc lựa chọn một tập huấn luyện phù hợp để đạt được sự khái quát hóa cho các máy phát điện tổng hợp không nhìn thấy được. Tập dữ liệu được chọn bao gồm các hình ảnh từ một kiến trúc thể hệ duy nhất (Pro-GAN) và 20 danh mục thực/sai khác nhau (Hình 3.a) và bao gồm tính năng tăng cường dưới dạng các hoạt động xử lý hậu kỳ hình ảnh phổ biến, chẳng hạn như làm mờ và nén. Kết quả cho thấy rõ ràng rằng tính tổng quát và tính mạnh mẽ được hưởng lợi rất nhiều từ nhiều danh mục khác nhau được đưa vào trong quá trình đào tạo cũng như từ quy trình tăng cường. Trên thực tế, tập dữ liệu này đã được sử dụng rộng rãi trong tài liệu, trong đó các nhà nghiên cứu tuân theo một giao thức chuẩn giả định kiến trúc về một mô hình tổng hợp duy nhất trong quá trình đào tạo. Kịch bản này mô tả một tình huống thực tế điển hình trong đó các kiến trúc tổng quát mới chưa được biết đến tại thời điểm thử nghiệm.

Tập dữ liệu được đề xuất trong [46] đã được sử dụng trong [33] để tinh chỉnh mô hình CLIP với một lớp tuyến tính có thể học được duy nhất, đạt được khả năng khái quát hóa tuyệt vời không chỉ trên các mô hình GAN mà còn trên các trình tạo tổng hợp dựa trên Khuếch tán chưa từng thấy trong quá trình đào tạo. Tương tự như vậy, nó được sử dụng trong [22] để huấn luyện bộ phân loại CNN tận dụng các tính năng được trích xuất từ các lớp trung gian của CLIP để khai thác tốt hơn các tính năng điều tra cấp thấp. Trong [40, 43] chú thích hình ảnh (được ghép nối với hình ảnh trong tập dữ liệu hoặc được tạo từ chúng) được sử dụng làm đầu vào bổ sung cho quá trình phân tích chung trong quá trình đào tạo. Cách tiếp cận được đề xuất trong [29] được đào tạo chỉ bằng 4 lớp trong số 20 loại được đề xuất trong [46], cũng như các phương pháp gần đây khác [41–43].

Ngoài ra, một số phương pháp dựa vào bộ dữ liệu bao gồm hình ảnh từ một trình tạo dựa trên khuếch tán duy nhất, chẳng hạn như Khuếch tán tiềm ẩn [7, 10, 11], Khuếch tán có hướng dẫn [47] hoặc Khuếch tán ổn định [23, 40]. Công việc trước đây [7, 11] nhấn mạnh tầm quan trọng của việc sắp xếp cả dữ liệu huấn luyện và dữ liệu kiểm tra về mặt nội dung ngữ nghĩa. Lựa chọn này cho phép khai thác tốt hơn tiềm năng của các tính năng CLIP tiền huấn luyện cố định bằng cách giảm mạnh số lượng hình ảnh cần thiết để tinh chỉnh [11]. Ngoài ra, nó còn có ưu điểm chính là giảm sai lệch nội dung tập dữ liệu, do đó cho phép đào tạo có chất lượng tốt hơn và cũng được áp dụng theo các phương pháp khác cả trong quá trình đào tạo [1, 3] và tại thời điểm thử nghiệm để thực hiện đánh giá công bằng hơn [2].

Tạo dữ liệu đào tạo bằng cách chèn tạo tác. Một hướng nghiên cứu khác là tạo ra các hình ảnh giả mô phỏng bằng cách đưa dấu vết của quá trình hình thành vào hình ảnh thật. Một công việc quan trọng dọc theo dòng này đã được thực hiện bởi Zhang et al. [56] để phát hiện hình ảnh GAN. Ý tưởng là mô phỏng các tạo phẩm được chia sẻ bởi một số máy phát điện. Những dấu vết đặc biệt này là do quá trình lấy mẫu nâng cao có trong quy trình tạo và hiển thị dưới dạng các đỉnh trong miền tần số. Bên cạnh các đỉnh tần số này, các hình ảnh tổng hợp, cả dựa trên GAN và dựa trên khuếch tán, đã được chứng minh là thể hiện các đặc điểm quang phổ rất khác so với các đặc điểm quang phổ của hình ảnh tự nhiên [15, 16]. Trên thực tế, hình ảnh thực thể hiện nội dung quang phổ phong phú hơn nhiều ở tần số trung gian so với hình ảnh tổng hợp [9, 49].

Đối với các hình ảnh do GAN tạo ra, việc tạo ra các hình ảnh giả mô phỏng thực tế đòi hỏi phải đào tạo kiến trúc tạo đặc biệt cho nhiệm vụ này [20, 56]. Ngược lại, việc tạo hình ảnh dựa trên khuếch tán có thể tận dụng bộ mã hóa tự động được đào tạo trước được nhúng trong quy trình tạo, chiếu hình ảnh vào không gian tiềm ẩn mà không cần đào tạo thêm [11, 31]. Quy trình này gần đây đã được sử dụng trong một công việc đồng thời [38] để giảm sai lệch ngữ nghĩa trong quá trình đào tạo (Hình 3.c). Khác với [38], chúng tôi tạo ra dữ liệu tổng hợp bằng cách thực hiện các bước khuếch tán. Phần sau của công việc này chúng tôi sẽ chỉ ra rằng sự lựa chọn này cho phép chúng tôi

Thẩm quyền giải quyết	#Thật/ #Giả	Nguồn thực	# Models
Tổng hợp [2]	1k / 9k	NÂNG LÊN	9
GenImage [57]	1.3M / 1.3M	ImageNet	8
Đảo ngược giả [7]	44.7k / 44.7k	internet	13
SynthWildX [11]	500 / 1.5k	X	3
WildRF [6]	1.25k / 1.25k	Reddit, FB, X	unknown

Bảng 1. Bảng này cung cấp thông tin tổng quan về các bộ dữ liệu được sử dụng trong đánh giá của chúng tôi, bao gồm số lượng hình ảnh thật và giả, nguồn dữ liệu thực và số lượng mô hình tổng hợp được sử dụng để tạo ra hình ảnh tổng hợp.

để khai thác những mâu thuẫn thậm chí còn tinh vi hơn ở tần số thấp hơn, nâng cao hiệu suất của máy dò (Hình 3.d).

3. Quy trình đánh giá

3.1. Bộ dữ liệu

Trong phân tích thử nghiệm của chúng tôi, chúng tôi muốn tránh hoặc ít nhất là giảm thiểu ảnh hưởng của bất kỳ sai lệch nào có thể được đề cập ở trên. Để đạt được mục đích này, chúng tôi lựa chọn cẩn thận các bộ dữ liệu đánh giá như được nêu dưới đây. Các thí nghiệm trên các bộ dữ liệu tiếp theo được cung cấp trong tài liệu bổ sung.

Để tránh sai lệch định dạng, chúng tôi sử dụng Synthbuster [2], trong đó có hình ảnh thực và hình ảnh được tạo đều được lưu ở định dạng thô. Do đó, hiệu suất tốt trên tập dữ liệu này không thể đến từ việc khai thác các tạo phẩm JPEG. Một chiến lược bổ sung để tránh sai lệch định dạng là giảm sự không khớp giữa hình ảnh thực (được nén) và hình ảnh tổng hợp (không nén) bằng cách nén hình ảnh sau. Để đạt được mục đích này, chúng tôi đã sửa đổi lớp giả trong GenImage [57] bằng cách nén hình ảnh ở chất lượng JPEG gần với chất lượng được sử dụng cho lớp thật, như được đề xuất trong [19]. Tập dữ liệu đã sửa đổi này, được gọi là GenImage unbiased, bao gồm 5k ảnh thật và 5k ảnh giả, một phần nhỏ của tập dữ liệu gốc.

Để tránh sai lệch nội dung, chúng tôi cũng đánh giá hiệu suất trên các tập dữ liệu trong đó hàng giả được tạo bằng cách sử dụng mô tả tự động về hình ảnh thật. Trong các nghiên cứu như [2, 3], những mô tả này được tinh chỉnh thành các lời nhắc được tạo thủ công để tạo dựa trên văn bản. Kết quả là, hình ảnh được tạo ra phù hợp chặt chẽ với nội dung của hình ảnh thực, giảm thiểu sai lệch có thể xảy ra do sự khác biệt về ngữ nghĩa. Một tập dữ liệu tinh tế hơn về vấn đề này là FakeInversion [7], trong đó hình ảnh thật được lấy từ web bằng cách sử dụng tìm kiếm hình ảnh ngược, do đó đảm bảo sự liên kết về mặt phong cách và chủ đề với hình ảnh giả.

Để cho phép phân tích thực tế, chúng tôi cũng thử nghiệm trên các tập dữ liệu hình ảnh thật/giả được thu thập từ web, chẳng hạn như WildRF [6] và SynthWildX [11]. Cả hai bộ dữ liệu đều bao gồm hình ảnh đến từ một số mạng xã hội phổ biến. Thử nghiệm sử dụng để tìm hình ảnh giả mạo trên Reddit, Facebook và X. Bản tóm tắt ngắn gọn về tất cả các tập dữ liệu được sử dụng trong đánh giá của chúng tôi được liệt kê trong Bảng 1.



Hình 4. Quá trình tăng cường nội dung. Bắt đầu với một hình ảnh thực, chúng tôi sử dụng các biến thể được tạo (hàng đầu tiên) và các phiên bản được xử lý cục bộ của chúng (hàng cuối cùng), được tạo bằng cách thay thế nền gốc. Khi vẽ bằng một danh mục khác, chúng tôi sử dụng hộp giới hạn thay vì mặt nạ đối tượng để tạo khoảng trống cho các đối tượng mới có hình dạng và kích thước khác nhau.

3.2. Số liệu

Hầu hết các công việc về phát hiện hình ảnh GenAI đều đo lường hiệu suất bằng các số liệu không phụ thuộc vào ngưỡng, chẳng hạn như Diện tích dưới đường cong (AUC) hoặc độ chính xác trung bình (AP). Các số liệu này cho thấy hiệu suất phân loại lý tưởng, tuy nhiên, ngưỡng phân tách tối ưu không được biết đến và, khá thường xuyên, độ chính xác cân bằng ở ngưỡng cố định (ví dụ: 0.5) vẫn ở mức thấp, đặc biệt khi có sự khác biệt đáng kể giữa phân phối đào tạo và phân phối thử nghiệm [44]. Một số bài báo giải quyết vấn đề này bằng cách điều chỉnh ngưỡng thông qua quy trình hiệu chuẩn, giả sử quyền truy cập vào một số hình ảnh từ bộ tạo tổng hợp đang được đánh giá [10, 33, 46]. Trong tình huống thực tế, tính khả dụng của các hình ảnh hiệu chỉnh như vậy không thể được đảm bảo.

Trong công việc này, để cung cấp đánh giá toàn diện về hiệu suất, chúng tôi sử dụng cả AUC và Độ chính xác ở mức 0.5, ngoài ra, chúng tôi còn tính toán Lỗi hiệu chuẩn dự kiến (ECE) và Khả năng ghi nhận ký âm (NLL). ECE đo lường khả năng của một mô hình trong việc cung cấp xác suất dự đoán phù hợp với xác suất thực. Chính xác hơn, chúng tôi sử dụng ECE nhị phân, là mức trung bình có trọng số của sự khác biệt giữa xác suất thực tế và xác suất dự đoán trên các nhóm khác nhau [35]. Sau đó, chúng tôi sử dụng Khả năng ghi nhận ký âm cân bằng [36], đánh giá sự giống nhau giữa phân phối dự đoán của mô hình và phân phối dữ liệu thực tế, xử phạt cả độ tin cậy thấp đối với lớp đúng và độ tin cậy quá mức đối với lớp không chính xác. Thông tin chi tiết hơn về các số liệu này có thể được tìm thấy trong tài liệu bổ sung.

		Synthbuster					New Generators		WildRF			AVG
Method	Training setting	Midjourney	SDXL	DALL-E 2	DALL-E 3	Firefly	FLUX	SD 3.5	Facebook	Reddit	Twitter	AUC↑/bAcc↑
AUC/bAcc	paired by text	96.9 / 56.9	99.5 / 78.1	78.7 / 50.1	98.8 / 56.6	91.3 / 51.1	94.6 / 51.5	96.6 / 66.9	97.8 / 72.5	84.4 / 67.2	96.1 / 68.1	93.5 / 61.9
	reconstructed	100. / 99.8	100. / 100.	81.1 / 52.2	99.1 / 75.8	96.7 / 62.1	98.2 / 64.0	99.7 / 88.8	98.9 / 97.5	77.8 / 75.5	94.8 / 91.1	94.6 / 80.7
	reconstructed	100. / 99.9	100. / 99.9	90.1 / 62.0	99.2 / 79.5	98.1 / 77.2	95.8 / 69.1	99.4 / 89.1	98.8 / 95.9	78.7 / 76.1	94.9 / 90.3	95.5 / 83.9
	self-conditioned	99.9 / 97.2	100. / 99.2	90.4 / 58.1	98.9 / 76.1	99.4 / 89.7	95.4 / 59.4	100. / 98.4	95.4 / 86.6	75.7 / 66.3	91.4 / 82.7	94.7 / 81.4
	self-conditioned	99.9 / 94.3	99.9 / 97.8	93.5 / 53.2	99.1 / 72.7	99.8 / 76.4	90.4 / 52.3	99.8 / 91.0	96.4 / 90.3	80.3 / 74.8	93.8 / 82.9	95.3 / 78.6
	"	100. / 99.4	100. / 99.6	96.7 / 77.8	99.4 / 92.8	99.9 / 99.2	98.7 / 87.5	99.9 / 98.4	98.9 / 94.4	89.4 / 81.2	97.5 / 92.0	98.0 / 92.2
NLL/ECE	"	99.9 / 98.8	100. / 99.7	99.7 / 95.9	99.6 / 96.8	100. / 99.6	97.9 / 85.3	99.3 / 95.1	98.0 / 95.0	96.0 / 89.8	99.4 / 96.5	99.0 / 95.2
	"	100. / 99.6	100. / 99.8	99.7 / 95.7	99.9 / 98.2	100. / 99.7	99.3 / 92.3	99.9 / 98.9	99.0 / 95.6	95.8 / 86.3	99.7 / 97.4	99.3 / 96.4
	paired by text	1.96 / .418	0.72 / .218	3.60 / .496	1.71 / .416	2.95 / .484	2.62 / .473	1.42 / .327	1.00 / .273	1.77 / .324	1.31 / .310	1.91 / .374
	reconstructed	0.00 / .003	0.00 / .001	3.33 / .469	0.83 / .240	1.56 / .368	1.46 / .354	0.38 / .115	0.13 / .025	1.20 / .192	0.43 / .082	0.93 / .185
	reconstructed	0.01 / .008	0.01 / .008	1.16 / .353	0.40 / .197	0.51 / .222	0.79 / .290	0.23 / .107	0.12 / .032	0.73 / .153	0.29 / .066	0.42 / .144
	self-conditioned	0.08 / .031	0.02 / .008	1.48 / .399	0.59 / .234	0.27 / .114	1.22 / .379	0.04 / .021	0.31 / .084	0.92 / .237	0.40 / .078	0.53 / .158
NLL/ECE	self-conditioned	0.14 / .063	0.06 / .028	1.66 / .440	0.67 / .268	0.48 / .238	1.82 / .452	0.22 / .103	0.29 / .076	0.77 / .162	0.48 / .141	0.66 / .197
	"	0.02 / .016	0.02 / .017	0.49 / .199	0.18 / .085	0.04 / .025	0.27 / .117	0.05 / .021	0.16 / .070	0.39 / .059	0.19 / .033	0.18 / .064
	"	0.04 / .008	0.01 / .006	0.12 / .044	0.10 / .037	0.02 / .011	0.40 / .149	0.14 / .044	0.17 / .032	0.25 / .043	0.11 / .028	0.14 / .040
	"	0.02 / .013	0.01 / .011	0.10 / .045	0.06 / .031	0.02 / .019	0.19 / .084	0.04 / .014	0.14 / .039	0.28 / .075	0.09 / .047	0.10 / .038


Bảng 2. Nghiên cứu cắt bỏ. Chúng tôi so sánh một số hình thức căn chỉnh nội dung và tăng cường nội dung. Hiệu suất xét về AUC/Độ chính xác (trên cùng) và ECE/NLL (dưới cùng). Lưu ý rằng tất cả các biến thể đều có chung một mức tăng tiêu chuẩn (lầm mờ + nén JPEG) như được đề xuất trong [46]. Để căn chỉnh nội dung, chúng tôi xem xét các chiến lược ghép nối hình ảnh được mô tả trong Hình 3: tạo văn bản, tái cấu trúc thông qua bộ mã hóa tự động và đề xuất của chúng tôi bằng cách sử dụng hình ảnh tự điều chỉnh. Đối với giải pháp cuối cùng, chúng tôi thử nghiệm một số hình thức tăng cường: cắt/hỗn hợp tiêu chuẩn và ba chiến lược được đề xuất dựa trên inpainting được mô tả trong Phần. 4.2. In đậm gạch chân hiệu suất tốt nhất cho mỗi cột với mức chênh lệch 1%.

4. Phương pháp đề xuất

Để hiện thực hóa và kiểm tra mô hình đào tạo không thiên vị của mình, chúng tôi:

- xây dựng một tập dữ liệu bao gồm các hình ảnh thật và hình ảnh giả được tạo ra, trong đó các hình ảnh giả được căn chỉnh tốt với các hình ảnh thật của chúng nhưng bao gồm các tạo tác pháp lý của quá trình tạo dựa trên khuếch tán. Bộ dữ liệu được tạo bắt đầu từ các hình ảnh được thu thập từ tập huấn luyện của bộ dữ liệu MS-COCO [28], với tổng số 51.517 hình ảnh thật. Sau đó, nó được làm phong phú thông qua một số hình thức tăng cường, bao gồm cả các hình ảnh được vẽ cục bộ và cuối cùng bao gồm 309.102 hình ảnh được tạo ra.
- sử dụng tập dữ liệu đã căn chỉnh này để tinh chỉnh mô hình dựa trên Vision Transformer (ViT) từ đầu đến cuối. Cụ thể, chúng tôi áp dụng một biến thể của mạng ViT được đề xuất trong [13] với bốn thanh ghi và sử dụng quá trình huấn luyện trước dựa trên phương pháp học tự giám sát DINOv2 [34]. Trong quá trình đào tạo, chúng tôi tránh thay đổi kích thước hình ảnh và dựa vào các phần cắt lớn 504×504 pixel. Tại thời điểm suy luận, chúng tôi cũng trích xuất các phần cắt có cùng kích thước từ hình ảnh (nếu hình ảnh lớn hơn, chúng tôi tính trung bình kết quả của nhiều phần cắt).


Để đảm bảo hình ảnh giả khớp với nội dung của hình ảnh thật về mặt ngữ nghĩa, chúng tôi khai thác cơ chế điều hòa của mô hình Khuếch tán ổn định cho phép chúng tôi kiểm soát quá trình tổng hợp thông qua đầu vào phụ, có thể là nhãn lớp, văn bản hoặc hình ảnh khác. Đầu vào bên trước tiên được chiếu thành biểu diễn trung gian bởi một bộ mã hóa miền cụ thể, sau đó cung cấp các lớp trung gian của bộ mã hóa tự động để khử nhiễu trong không gian nhúng. Sau một số bước khử nhiễu, bộ giải mã được sử dụng để thu được hình ảnh tổng hợp có điều kiện từ vector nhúng (Xem Hình 1). Trong thể hệ tự điều hòa của chúng tôi, chúng tôi sử dụng mô hình khuếch tán nội tại của Khuếch tán ổn định 2.1 [39], có ba mặt trong-



Hình 5. Phổ công suất được tính bằng cách lấy trung bình (2000 hình ảnh) sự khác biệt giữa: (a) hình ảnh thật và hình ảnh tái tạo, (b) hình ảnh thật và hình ảnh tự điều chỉnh, và (c) hình ảnh tái tạo và hình ảnh tự điều chỉnh. Chúng ta có thể quan sát thấy rằng thể hệ tự điều hòa nhúng các tạo tác pháp y ngay cả ở tần số thấp hơn so với các hình ảnh được tái tạo. Điều này có nghĩa là có thể khai thác tốt hơn những mẫu thuận đó để phân biệt hàng thật và hàng giả.

đặt: hình ảnh tham chiếu, mặt nạ nhị phân của khu vực cần sơn và mô tả văn bản. Sử dụng mặt nạ trống, chúng tôi tạo ra các bước khuếch tán để tạo lại đầu vào, nghĩa là tạo ra một hình ảnh mới có cùng nội dung với hình ảnh đầu vào. Đối với quá trình tăng cường nội dung, chúng tôi sử dụng phương pháp inpainting Stable Diffusion 2.1 để thay thế một đối tượng bằng một đối tượng mới, được chọn từ cùng danh mục hoặc từ một danh mục khác. Hơn nữa, như trong Hình 4, bên cạnh tính năng inpaint mặc định, giúp tái tạo toàn bộ hình ảnh, chúng tôi cũng xem xét một phiên bản trong đó nền gốc được lưu trữ. Lưu ý rằng trong quá trình đào tạo, chúng tôi cân bằng giữa lớp thật và lớp giả, lấy số lượng hình ảnh bằng nhau từ mỗi lớp.

Sau đây, chúng tôi trình bày nghiên cứu cắt bỏ của chúng tôi. Để tránh sai lệch dữ liệu, chúng tôi sử dụng WildRF và Synthbuster. Ngoài ra, chúng tôi thử nghiệm trên các hình ảnh 1000 FLUX và 1000 Stable Diffusion 3.5, là một số trình tạo tổng hợp mới nhất.



Hình 6. Phân tích độ chắc chắn về mặt cân bằng Độ chính xác được thực hiện trên chín trình tạo của bộ dữ liệu Synthbuster.

4.1. Ảnh hưởng của việc căn chỉnh nội dung

Trong Tab. 2, chúng tôi cho thấy hiệu suất đạt được với các chiến lược căn chỉnh tập dữ liệu khác nhau, như được mô tả trong Hình 3. Lưu ý rằng tất cả các biến thể đều được huấn luyện với các mức tăng tiêu chuẩn, bao gồm làm mờ và nén JPEG, như được đề xuất trong [46]. Từ Bảng, chúng ta có thể nhận thấy rằng có mức tăng lớn về độ chính xác cân bằng ($\approx 20\%$) khi chuyển từ thể hệ dựa trên văn bản (hàng đầu tiên) sang giải pháp trong đó hình ảnh thật và giả chia sẻ nội dung ngữ nghĩa, cả được xây dựng lại và tự điều chỉnh. Giải pháp được đề xuất sử dụng phương pháp khuếch tán cho thấy sự cải thiện trung bình hơn nữa trên tất cả các số liệu đánh giá. Điều này được làm nổi bật trong Hình 5, trong đó chúng tôi hiển thị phổ công suất được đánh giá bằng cách lấy trung bình sự khác biệt giữa hình ảnh thực và hình ảnh được tái tạo cũng như hình ảnh thực và hình ảnh tự điều chỉnh. Chúng tôi quan sát thấy rằng thể hệ tự điều hòa tạo ra các tạo tác pháp y ngay cả ở tần số thấp nhất, cho thấy máy dò được đào tạo về những hình ảnh như vậy có thể khai thác sự không nhất quán trên dải tần số rộng hơn.

4.2. Tác dụng của việc tăng cường nội dung

Chúng tôi cũng phân tích tác động của các chiến lược tăng cường nội dung khác nhau (Hình 4). Chúng tôi xem xét các hoạt động tiêu chuẩn như cắt-trộn [52] và trộn [55] và so sánh chúng với các giải pháp được đề xuất của chúng tôi bao gồm ba biến thể:

- *không được vẽ*, chúng tôi thay thế một đối tượng bằng một đối tượng khác cùng danh mục cộng với phiên bản trong đó nền được thay thế bằng các pixel nguyên sơ (thực chất là chỉnh sửa hình ảnh cục bộ);
- *không được vẽ+*, chúng tôi thay thế một đối tượng bằng một đối tượng khác thuộc cả cùng loại và khác danh mục cộng với các phiên bản tương ứng trong đó nền được thay thế bằng các pixel nguyên sơ;
- *không được son++*, chúng tôi bổ sung thêm một số thao tác tăng cường tiêu chuẩn khác, chẳng hạn như chia tỷ lệ, cắt bớt, thêm nhiễu và biến dạng.

Nhìn chung, điều đó được thể hiện rõ ràng từ Tab. 2 rằng việc tăng cường đóng một vai trò quan trọng trong việc tăng cường tổng quát hóa mô hình và điều này có thể được đánh giá cao đặc biệt bằng cách xem xét các biện pháp hiệu chuẩn và độ chính xác cân bằng. Trên thực tế, việc thêm inpaint-

Architecture	FT	AUC $\uparrow$	bAcc $\uparrow$	NLL $\downarrow$	ECE $\downarrow$
DINOv2+reg	LP	80.8	68.5	0.58	.141
DINOv2+reg	e2e	99.0	95.2	0.14	.040
DINOv2	e2e	98.4	91.1	0.24	.077
SigLIP	e2e	95.4	89.9	0.28	.066

Bảng 3. Chúng tôi so sánh giải pháp DINOv2+reg được đào tạo từ đầu đến cuối của mình với thăm dò tuyến tính (LP) và cũng xem xét các kiến trúc thay thế, DINOv2 và SigLIP cơ bản.

Architecture	Training Set	AUC $\uparrow$	bAcc $\uparrow$	NLL $\downarrow$	ECE $\downarrow$
CLIP/ViT	ProGAN [46]	54.7	45.2	4.85	.525
	LDM [10]	63.9	48.5	3.39	.487
	Ours	75.2	73.9	0.66	.225
RINE	ProGAN [46]	66.1	65.0	5.43	.312
	LDM [10]	83.0	75.7	0.53	.132
	Ours	89.9	83.2	0.39	.089

Bảng 4. Nghiên cứu cắt bỏ về ảnh hưởng của dữ liệu huấn luyện (Pro-GAN, Latent Diffusion và tập dữ liệu của chúng tôi) đối với các phương pháp được sử dụng để phát hiện hình ảnh do AI tạo ra: CLIP [37] và RINE [22].

Việc tái thiết làm tăng độ chính xác từ 80,7 lên 83,9, trong khi việc sử dụng chung tính năng tự điều hòa và son lại sẽ mang lại mức tăng thêm đáng kể, đạt 92,2 hoặc thậm chí 96,4 với *không son++*. Mức tăng đáng kể nhất được quan sát thấy trên DALL·E 2, DALL·E 3 và FLUX, có lẽ, khác biệt nhiều nhất so với Stable 2.1 về mặt kiến trúc và do đó cần có chiến lược tăng cường mạnh mẽ hơn để khái quát hóa.

Trong Hình 6, chúng tôi phân tích tác động của việc tăng cường nội dung, đánh giá độ chắc chắn trong các hoạt động khác nhau: nén JPEG, thay đổi kích thước và làm mờ. Tất cả ba biến thể tăng cường được đề xuất đều mang lại lợi thế rõ ràng, đặc biệt là khi áp dụng thay đổi kích thước. Việc sử dụng chung phương pháp tự điều hòa và son nội bộ mang lại phương pháp tiếp cận mạnh mẽ nhất.

4.3. Ảnh hưởng của dữ liệu và kiến trúc đào tạo

Chúng tôi tiến hành các thử nghiệm bổ sung để hiểu rõ hơn về tác động của kiến trúc đã chọn và dữ liệu đào tạo được đề xuất trên cùng các tập dữ liệu được hiển thị trong Tab. 2.

Trước tiên, chúng tôi so sánh mô hình được áp dụng của chúng tôi, DINOv2+reg được đào tạo từ đầu đến cuối, với chiến lược tinh chỉnh thay thế chỉ liên quan đến việc đào tạo lớp tuyến tính cuối cùng, được gọi là thăm dò tuyến tính (LP) được áp dụng rộng rãi trong tài liệu [11, 33]. Từ Tab. 3, chúng ta có thể thấy rằng giải pháp sau này hoạt động không tốt. Một lời giải thích có thể là các tính năng từ lớp cuối cùng nắm bắt ngữ nghĩa cấp cao, trong khi tập dữ liệu của chúng tôi được xây dựng để khai thác các tạo phẩm cấp thấp xuất phát từ lớp đầu tiên và lớp trung gian [10, 22]. Trong cùng một Bảng, chúng tôi so sánh DINOv2+reg với kiến trúc DINOv2 [34] cơ bản và SigLIP [53] và chúng tôi có thể quan sát thấy rằng DINOv2 với việc sử dụng các thanh ghi sẽ đạt được hiệu suất tốt nhất, có lẽ nhờ vào thực tế là nó tránh loại bỏ thông tin bản và cục bộ [13].

bAcc(%) $\uparrow$ /NLL $\downarrow$	Synthbuster					New Generators		WildRF			AVG
	Midjourney	SDXL	DALL-E 2	DALL-E 3	Firefly	FLUX	SD 3.5	Facebook	Reddit	Twitter	bAcc $\uparrow$ /NLL $\downarrow$
CNNDetect	49.5 / 8.45	49.8 / 6.90	50.2 / 5.75	49.5 / 12.9	50.3 / 3.66	49.5 / 10.1	50.0 / 5.30	50.0 / 9.84	50.7 / 6.66	50.1 / 8.64	50.0 / 7.83
DMID	100. / 0.00	99.7 / 0.01	50.1 / 5.99	50.0 / 7.08	51.0 / 1.72	63.7 / 1.27	99.9 / 0.01	87.8 / 0.52	74.3 / 1.82	79.1 / 0.85	75.6 / 1.93
LGrad	57.7 / 6.88	58.5 / 6.81	55.6 / 7.10	47.9 / 7.58	47.4 / 7.50	54.9 / 7.11	51.9 / 7.24	66.6 / 3.74	57.8 / 4.72	45.7 / 5.31	54.4 / 6.40
UnivFD	52.4 / 2.35	68.0 / 1.15	83.5 / 0.43	47.3 / 3.94	90.7 / 0.24	48.4 / 3.45	69.3 / 1.07	48.8 / 3.06	59.5 / 1.37	56.0 / 2.01	62.4 / 1.91
DeFake	69.7 / 0.72	76.3 / 0.56	64.0 / 0.92	84.9 / 0.36	72.4 / 0.63	79.2 / 0.46	81.2 / 0.42	66.3 / 0.89	65.9 / 0.82	63.4 / 0.94	72.3 / 0.67
DIRE	49.7 / 15.3	49.9 / 15.3	50.0 / 15.3	50.0 / 15.3	49.9 / 15.3	50.0 / 15.3	50.0 / 15.3	51.9 / 4.98	79.5 / 2.15	56.7 / 4.39	53.7 / 11.9
AntifakePrompt	70.4 / -	84.7 / -	65.5 / -	86.0 / -	70.0 / -	59.6 / -	60.7 / -	69.7 / -	68.9 / -	78.0 / -	71.3 / -
NPR	44.9 / 16.6	50.3 / 16.2	50.2 / 16.2	0.6 / 29.9	0.4 / 47.3	50.3 / 16.2	50.3 / 16.2	50.0 / 32.2	78.3 / 9.39	51.8 / 25.2	42.7 / 22.5
FatFormer	44.4 / 5.22	66.7 / 2.76	54.1 / 3.64	35.9 / 6.90	60.1 / 3.59	39.4 / 6.10	49.1 / 5.06	54.7 / 4.54	69.5 / 2.54	54.8 / 4.40	52.9 / 4.48
FasterThanLies	61.3 / 2.98	71.1 / 1.79	50.8 / 5.15	53.5 / 3.79	55.2 / 4.40	53.8 / 4.10	53.7 / 3.76	46.2 / 3.32	51.0 / 3.99	53.9 / 3.31	55.1 / 3.66
RINE	54.6 / 5.03	71.8 / 1.99	82.2 / 0.77	45.3 / 20.5	91.2 / 0.36	46.7 / 10.1	81.3 / 1.22	52.8 / 6.51	67.7 / 2.46	56.0 / 5.23	65.0 / 5.43
AIDE	57.5 / 0.95	68.4 / 0.70	34.9 / 1.34	33.7 / 1.38	24.8 / 2.00	62.9 / 0.82	63.3 / 0.82	56.9 / 0.94	72.1 / 0.62	57.3 / 1.01	53.2 / 1.06
LaDeDa	50.7 / 24.8	50.7 / 24.8	50.5 / 24.8	41.1 / 25.4	47.4 / 25.6	50.5 / 24.8	50.7 / 24.8	70.3 / 7.19	74.7 / 7.93	59.6 / 9.40	54.6 / 19.9
C2P-CLIP	52.8 / 1.10	77.7 / 0.48	55.6 / 0.99	63.2 / 0.73	59.5 / 0.89	50.1 / 1.30	60.9 / 0.93	54.4 / 0.97	68.4 / 0.67	57.4 / 0.91	60.0 / 0.90
CoDE	76.9 / 0.82	75.2 / 0.81	54.6 / 2.44	73.2 / 0.98	58.6 / 2.00	59.8 / 1.97	60.7 / 1.27	70.0 / 0.97	66.1 / 1.29	70.9 / 1.01	67.3 / 1.36
B-Free (ours)	99.6 / 0.02	99.8 / 0.01	95.6 / 0.10	98.2 / 0.06	99.7 / 0.02	92.3 / 0.19	98.9 / 0.04	95.6 / 0.14	86.2 / 0.28	97.3 / 0.09	96.3 / 0.10

Bảng 5. So sánh với các phương pháp SoTA về Độ chính xác cân bằng và NLL cân bằng trên các máy phát khác nhau. Lưu ý rằng AntifakePrompt [8] chỉ cung cấp nhãn nhị phân cứng do đó không thể tính toán được các biện pháp hiệu chuẩn. In đậm gạch chân hiệu suất tốt nhất cho mỗi cột với biên độ 1%.

Sau đó, trong Tab. Như được hiển thị trong Hình 4, chúng tôi xem xét mô hình dựa trên CLIP và kiến trúc của RINE, đồng thời thay đổi tập dữ liệu huấn luyện bằng cách bao gồm hai tập dữ liệu nổi tiếng được sử dụng rộng rãi trong tài liệu, một dựa trên ProGAN [46] và tập dữ liệu còn lại dựa trên Khuếch tán tiềm ẩn [10]. Chúng tôi lưu ý rằng mô hình đào tạo của chúng tôi đạt được hiệu suất tốt nhất trên tất cả các số liệu với mức tăng rất lớn (RINE tăng độ chính xác từ 65% lên 83,2%).

5. So sánh với công nghệ tiên tiến nhất

In this Section, we conduct a comparison with SoTA methods on 27 diverse synthetic generation models. To ensure fairness, we include only SoTA methods with publicly available code and/or pre-trained models. The selected methods are listed in Table 6 and are further described in the supplementary material together with additional experiments. For all the experiments now on, *ours* refers to the detector trained using *inpainted++* augmentation.


A first experiment is summarized in Tab. 5 with results given in terms of balanced accuracy and NLL. Most of the methods struggle to achieve a good accuracy, especially on more recent generators. Instead, B-Free obtains a uniformly good performance on all generators, irrespective of the image origin, whether they are saved in raw format or downloaded from social networks, outperforming the second best (see last column) by +20.7% in terms of bAcc. Then, we evaluate again all methods on GenImage (unbiased), FakeInversion [7], and SynthWildX [11]. As these datasets encompass multiple generators, we only report the average performance in Tab. 7. On these additional datasets, most methods provide unsatisfactory results, especially in the most challenging scenario represented by SynthWildX, with images that are shared over the web. The proposed method performs well on all datasets, just a bit worse on FakeInversion. Finally in Fig. 7 we study how AUC com-

Ref.	Acronym	Training Real/Fake	Size (K)	Aug.
[46]	CNNDetect	LSUN / ProGAN	360 / 360	✓
[10]	DMID	COCO, LSUN / Latent	180 / 180	✓
[41]	LGrad	LSUN / ProGAN	72 / 72	✓
[33]	UnivFD	LSUN / ProGAN	360 / 360	✓
[40]	DeFake	COCO / SD	20 / 20	
[47]	DIRE	LSUN-Bed / ADM	40 / 40	
[8]	AntifakePrompt	COCO / SD3,SD2-inp	90 / 60	✓
[42]	NPR	LSUN / ProGAN	72 / 72	
[29]	FatFormer	LSUN / ProGAN	72 / 72	
[23]	FasterThanLies	COCO / SD	108 / 542	✓
[22]	RINE	LSUN / ProGAN	72 / 72	✓
[48]	AIDE	ImageNet / SD 1.4	160 / 160	✓
[6]	LaDeDa	LSUN / ProGAN	360 / 360	
[43]	C2P-CLIP	LSUN / ProGAN	72 / 72	✓
[3]	CoDE	LAION / SD1.4, SD2.1, SDXL, DeepF. IF	2.3M / 9.2M	✓
B-Free (ours)		COCO / SD2.1	51 / 309	✓


Bảng 6. Các phương pháp phát hiện hình ảnh do AI tạo ra được sử dụng để so sánh và mã của chúng được công bố rộng rãi. Chúng tôi chỉ định nguồn và kích thước của tập dữ liệu huấn luyện cũng như liệu việc tăng cường có được áp dụng hay không.

pares với độ chính xác cân bằng cho tất cả các phương pháp trên một số bộ dữ liệu. Chúng tôi quan sát thấy rằng một số phương pháp, như NPR và LGrad, thể hiện hành vi không đồng nhất rõ ràng, với hiệu suất rất tốt trên một tập dữ liệu duy nhất và tệ hơn nhiều trên các tập dữ liệu khác. Điều này dường như gợi ý rằng các phương pháp này có thể không thực sự phát hiện được các tạo tác pháp y, thay vào đó, chúng chỉ khai thác những thành kiến nội tại trong tập dữ liệu. Khác biệt, phương pháp được đề xuất thể hiện hiệu suất đồng đều trên tất cả các tập dữ liệu và có sự mất mát nhỏ giữa AUC và độ chính xác.

Phân tích nội dung được chia sẻ trực tuyến. Việc phân biệt hình ảnh thật với hình ảnh tổng hợp trên mạng xã hội có thể đặc biệt khó khăn do có nhiều lần đăng lại làm giảm chất lượng hình ảnh theo thời gian. Một nghiên cứu gần đây được tiến hành trong [21] đã phân tích hành vi của máy dò trên các trường hợp khác nhau của một hình ảnh được chia sẻ trực tuyến, cho thấy rằng



Hình 7. Hiệu suất trung bình về AUC và bAcc trên bốn bộ dữ liệu: Synthbuster, GenImage, FakeInversion, SynthWildX.



Hình 8. Kết quả của máy dò SoTA đối với hình ảnh thật và giả lan truyền trên internet, phân tích nhiều phiên bản được quét trên web của mỗi hình ảnh. Hiệu suất dựa trên độ chính xác cân bằng được đánh giá từ bài đăng trực tuyến ban đầu (Thang đo nhật ký). Chỉ các máy dò có độ chính xác trên 50% mới được hiển thị.

hình thức xuống cấp rõ rệt theo thời gian do đăng lại nhiều lần. Để hiểu rõ hơn về tác động của chiến lược tăng cường đối với những hình ảnh như vậy, chúng tôi đã thu thập tổng cộng 1400 hình ảnh thật/giả lan truyền trên mạng, bao gồm một số phiên bản của cùng một hình ảnh thật hoặc giả.

Hình 8 minh họa độ chính xác, được đánh giá trong khoảng thời gian 100 ngày kể từ thời điểm xuất bản lần đầu, với thời gian tính theo thang logarit. Chúng tôi so sánh đề xuất của mình với các phương pháp SoTA hoạt động tốt nhất. Chúng ta có thể nhận thấy rằng hiệu suất giảm chỉ sau một ngày, sau đó hầu hết các đối thủ cạnh tranh đều bị kẹt dưới 70%, ngoại trừ DeFake đạt khoảng 75%. Chỉ có phương pháp được đề xuất, bao gồm khả năng tăng cường tích cực hơn, mới có thể đảm bảo độ chính xác trung bình khoảng 92% ngay cả sau nhiều ngày kể từ bài đăng trực tuyến đầu tiên.

6. Hạn chế

Phương pháp được đề xuất trong công việc này được đào tạo bằng cách sử dụng các hình ảnh giả là các bản tái tạo tự điều chỉnh từ mô hình Khuếch tán ổn định 2.1. Nếu trong tương lai các máy phát điện mới có quy trình tổng hợp hoàn toàn khác sẽ được triển khai thì rất có thể phương pháp này sẽ thất bại (các nguyên tắc và ý tưởng được chia sẻ trong công việc này có thể vẫn được giữ nguyên). Lòng thú-

bAcc(%) $\uparrow$ /NLL $\downarrow$	GenImage	FakeInver.	SynthWildX	AVG
CNNDetect	51.3 / 7.88	50.9 / 7.94	50.0 / 8.08	50.7 / 7.96
DMID	79.0 / 1.66	96.1 / 0.25	76.6 / 0.82	83.9 / 0.91
LGrad	39.6 / 7.12	77.2 / 2.27	46.3 / 5.53	54.3 / 4.97
UnivFD	65.5 / 1.31	52.8 / 2.19	52.5 / 2.55	56.9 / 2.02
DeFake	73.7 / 0.74	63.3 / 0.95	62.9 / 0.98	66.6 / 0.89
DIRE	47.3 / 6.54	51.8 / 13.4	52.5 / 4.60	50.5 / 8.19
AntifakePrompt	78.5 / -	53.9 / -	70.8 / -	67.8 / -
NPR	50.7 / 25.3	87.0 / 4.96	49.9 / 28.2	62.6 / 19.5
FatFormer	61.5 / 3.99	59.7 / 3.45	53.3 / 4.75	58.2 / 4.06
FasterThanLies	77.0 / 1.23	48.6 / 3.64	50.9 / 3.40	58.8 / 2.76
RINE	69.1 / 2.57	63.6 / 4.84	56.2 / 6.07	63.0 / 4.49
AIDE	60.2 / 1.01	76.9 / 0.54	55.0 / 1.05	64.0 / 0.86
LaDeDa	50.2 / 29.2	84.7 / 3.03	55.1 / 10.2	63.3 / 14.1
C2P-CLIP	75.5 / 0.57	59.6 / 0.82	57.4 / 0.91	64.2 / 0.76
CoDE	71.7 / 1.43	78.8 / 0.74	72.3 / 0.95	74.2 / 1.04
B-Free (ours)	89.3 / 0.27	86.2 / 0.32	95.6 / 0.14	90.4 / 0.24

Bảng 7. So sánh với các phương pháp SoTA về hiệu suất trung bình về độ chính xác cân bằng và NLL cho ba bộ dữ liệu bổ sung: GenImage, FakeInversion và SynthWildX.

do đó, là một cách tiếp cận dựa trên dữ liệu, nó có thể bị tấn công bất lợi bởi người dùng độc hại. Đây là một vấn đề rất phù hợp mà chúng tôi dự định giải quyết trong công việc tương lai của mình.

7. Kết luận

Trong bài viết này, chúng tôi đề xuất một mô hình đào tạo mới để phát hiện hình ảnh do AI tạo ra. Trước hết, chúng tôi chứng minh bằng thực nghiệm tầm quan trọng của việc ghép ảnh thật và ảnh giả bằng cách hạn chế chúng có cùng nội dung ngữ nghĩa. Điều này giúp trích xuất tốt hơn các tạo phẩm phổ biến được chia sẻ trên các trình tạo tổng hợp khác nhau. Sau đó, chúng tôi nhận thấy rằng việc sử dụng tính năng tăng cường dữ liệu linh hoạt, dưới hình thức thao tác từng phần, sẽ nâng cao hơn nữa hiệu suất cả về độ chính xác và số liệu hiệu chuẩn. Điều này cực kỳ phù hợp, đặc biệt khi làm việc trong các tình huống thực tế, chẳng hạn như chia sẻ hình ảnh qua mạng xã hội. Phát hiện của chúng tôi nhấn mạnh rằng việc quản lý dữ liệu cẩn thận và chiến lược đào tạo phù hợp có thể có tác động mạnh hơn so với việc phát triển các thuật toán phức tạp hơn. Chúng tôi hy vọng công việc này sẽ truyền cảm hứng cho các nhà nghiên cứu khác trong cộng đồng pháp y theo đuổi hướng đi tương tự, thúc đẩy những tiến bộ trong chiến lược đào tạo không thiên vị.

Lời cảm ơn. Chúng tôi chân thành cảm ơn sự hỗ trợ của Google Gift cho nghiên cứu này. Ngoài ra, công việc này đã nhận được tài trợ từ Liên minh Châu Âu trong dự án Horizon Europe vera.ai, Thỏa thuận tài trợ số 101070093 và được SER-ICS (PE00000014) hỗ trợ một phần trong Kế hoạch Phục hồi và Phục hồi Quốc gia MUR, do Liên minh Châu Âu - NextGen- erationEU tài trợ.

Tài liệu bổ sung

Trong tài liệu bổ sung này, chúng tôi báo cáo thêm chi tiết về việc triển khai của chúng tôi (Phần A). Ngoài ra, chúng tôi mô tả ngắn gọn trạng thái của các phương pháp hiện đại mà chúng tôi so sánh với (Phần B) và cung cấp thêm chi tiết về số liệu hiệu chuẩn được sử dụng trong các thử nghiệm (Phần C). Chúng tôi cũng cung cấp kết quả cắt bỏ bổ sung trong Sec. D và thực hiện các thử nghiệm sâu hơn về khái quát hóa (Phần E) trên các bộ dữ liệu bổ sung có sẵn công khai. Hơn nữa, chúng tôi cung cấp nhiều kết quả hơn về tính chắc chắn của phương pháp tiếp cận của chúng tôi so với các phương pháp SoTA (Phần F).


A. Chi tiết thực hiện

Chiến lược đào tạo. Mô hình đề xuất tận dụng mạng nhúng hình ảnh DI-NOv2+reg [13, 34] 504×504 làm xương sống, theo sau là lớp được kết nối đầy đủ. Mô hình được đào tạo từ đầu đến cuối bằng cách sử dụng hàm mất entropy chéo nhị phân trên GPU NVIDIA A100. Quá trình đào tạo sử dụng trình tối ưu hóa ADAM với tốc độ học là $1e-6$, độ giảm trọng số là $1e-6$ và kích thước lô là 24.

Trong quá trình đào tạo, độ chính xác cân bằng được đánh giá trên bộ xác thực sau mỗi 3435 lần lặp. Việc dừng sớm được áp dụng để ngăn chặn việc trang bị quá mức: quá trình đào tạo được hoàn thành nếu độ chính xác của cân bằng xác thực không cải thiện ít nhất 0,1% trong năm lần đánh giá liên tiếp.

Chiến lược thử nghiệm. Nếu hình ảnh thử nghiệm nhỏ hơn 504 pixel, phần đệm sẽ được áp dụng sau khi nhúng bản vá. Mặt khác, chúng tôi tính trung bình điểm logit qua nhiều lần cắt để phân tích toàn bộ hình ảnh.

Tập dữ liệu huấn luyện. Ở đây chúng tôi cung cấp thêm thông tin chi tiết về cách chúng tôi xây dựng tập dữ liệu của mình. Bắt đầu từ tập huấn luyện MS-COCO, bao gồm 118K hình ảnh với 80 loại đối tượng, trước tiên chúng tôi loại bỏ các hình ảnh có giấy phép khác với Creative Commons. Trước khi chỉnh sửa hình ảnh, chúng tôi đã trích xuất phần cắt trung tâm lớn nhất, cho phép chúng tôi giữ lại hầu hết nội dung ngữ nghĩa của ảnh gốc. Chúng tôi đã loại bỏ những hình ảnh không có vật thể và thu được nguồn nguyên sơ gồm 51.517 hình ảnh. Để tăng cường nội dung, chúng tôi đã thay thế đối tượng đã chọn bằng một đối tượng được tạo từ cùng danh mục bằng cách sử dụng mặt nạ phân đoạn COCO và từ một danh mục khác bằng cách sử dụng hộp hình chữ nhật. Chúng tôi đã cẩn thận để không ảnh hưởng quá nhiều đến tính hiện thực của nội dung, vì vậy, đối tượng trong trường hợp “danh mục khác”



Hình 9. Ví dụ về hình ảnh được tăng cường nội dung từ tập dữ liệu huấn luyện của chúng tôi. Từ hình ảnh thực (hàng đầu tiên), chúng tôi tạo ra các phiên bản không được vẽ có cùng nội dung (hàng thứ hai) và nội dung khác nhau (hàng thứ ba).

được thay đổi bằng một danh mục từ danh mục tương tự, thuộc cùng siêu danh mục COCO. Trong kịch bản này, ngoại lệ duy nhất là danh mục *người*, không có siêu danh mục và do đó nó được thay thế bằng một đối tượng ngẫu nhiên. Như đã đề cập trong bài viết chính, bên cạnh tính năng inpainting mặc định, chúng tôi cũng xem xét một phiên bản trong đó chúng tôi lấy các pixel của đối tượng từ hình ảnh được tạo và các pixel của nền từ ảnh gốc. Chúng tôi cũng làm như vậy với hình ảnh tự điều chỉnh, khôi phục nền bằng các pixel gốc. Do đó, chúng tôi đã tạo ra sáu phiên bản giả cho mỗi ảnh thật (Hình 4).

B. Phương pháp SoTA

Dưới đây chúng tôi cung cấp mô tả ngắn gọn về các phương pháp mà chúng tôi đưa vào so sánh ở Phần 5. Các tập dữ liệu huấn luyện được sử dụng bởi các phương pháp này được chỉ ra trong Bảng 6.

CNNDetect [46]. Đây là một trình phát hiện dựa trên CNN được xây dựng trên ResNet50 (được đào tạo trước trên ImageNet) để hỗ trợ việc tăng cường dưới dạng các hoạt động xử lý hậu kỳ, chẳng hạn như làm mờ và nén.

DMID [10]. Công việc này cũng dựa trên ResNet-50, nhưng nó ngăn chặn việc lấy mẫu xuống ở lớp đầu tiên để bảo toàn các manh mối pháp y vô hình nhiều nhất có thể và sử dụng khả năng tăng cường mạnh hơn để tăng độ mạnh mẽ.

LGrad [41]. Công việc này cũng dựa trên bộ phân loại ResNet-50, nhưng điều này được cung cấp bởi một biểu diễn tạo tác tổng quát của hình ảnh dưới dạng độ dốc. Biểu diễn này được thiết kế để nắm bắt hiệu quả hơn các hiện vật được tạo ra bởi các trình tạo tổng hợp.

Đại họcFD [33]. Nó khai thác các tính năng CLIP được đào tạo trước thông qua

	Synthbuster					New Generators		WildRF			AVG
Training dataset	Midjourney	SDXL	DALL-E 2	DALL-E 3	Firefly	FLUX	SD 3.5	Facebook	Reddit	Twitter	AUC↑/bAcc↑
D ³ [3]	99.8 / 85.3	100. / 99.4	100. / 87.5	100. / 90.1	100. / 89.7	98.8 / 63.1	99.9 / 96.4	98.3 / 88.8	95.4 / 86.7	98.1 / 88.2	99.0 / 87.5
Ours	99.9 / 98.8	100. / 99.7	99.7 / 95.9	99.6 / 96.8	100. / 99.6	97.9 / 85.3	99.3 / 95.1	98.0 / 95.0	96.0 / 89.8	99.4 / 96.5	99.0 / 95.2
Training dataset	Midjourney	SDXL	DALL-E 2	DALL-E 3	Firefly	FLUX	SD 3.5	Facebook	Reddit	Twitter	NLL↓/ECE↓
D ³ [3]	0.33 / .156	0.03 / .016	0.27 / .146	0.22 / .120	0.22 / .138	1.07 / .350	0.11 / .048	0.26 / .101	0.32 / .079	0.28 / .105	0.31 / .126
Ours	0.04 / .008	0.01 / .006	0.12 / .044	0.10 / .037	0.02 / .011	0.40 / .149	0.14 / .044	0.17 / .032	0.25 / .043	0.11 / .028	0.14 / .040

Table 8. Ablation study on the influence of the training data. We compare the proposal with the same architecture DINOv2+reg trained on a publicly available dataset, D³ [3], that includes 4 generators from the Stable Diffusion family. Performance are presented in terms of AUC/Accuracy (top) and ECE/NLL (bottom).

thăm dò tuyến tính. Việc tính chỉnh được thực hiện trên cùng một tập dữ liệu gồm hình ảnh thực và hình ảnh do GAN tạo ra như trong [46].

Giả mạo [40]. Cả hình ảnh và lời nhắc tương ứng của chúng đều được sử dụng và đưa vào bộ mã hóa hình ảnh và văn bản của CLIP. Các đặc trưng được trích xuất là đầu vào của một perceptron đa lớp được huấn luyện để phát hiện nhị phân.

TUYỆT VỚI [47]. Nó sử dụng lỗi xây dựng lại của mô hình tổng quát làm đầu vào của ResNet-50. Trên thực tế, sai số này được cho là sẽ thấp hơn đối với hình ảnh tổng hợp so với hình ảnh thật.

AntifakePrompt [8]. Nó dựa trên công cụ trả lời câu hỏi trực quan (VQA), InstructBLIP. VQA được sử dụng với một câu hỏi cố định “Ảnh này có thật không?” và được tinh chỉnh để đưa ra câu trả lời chính xác (“Có” hoặc “Không”) bằng cách sử dụng kỹ thuật điều chỉnh nhắc nhở nhẹ nhàng. Lưu ý rằng phương pháp này cung cấp các dự đoán nhị phân cứng do đó chỉ có thể tính được độ chính xác.

NPR [42]. Trong trường hợp này, ResNet-50 được cung cấp bằng cách sử dụng hình ảnh dự được tính toán là sự khác biệt giữa hình ảnh gốc và phiên bản nội suy của nó. Ý tưởng là khai thác các tạo phẩm liên quan đến quá trình lấy mẫu lên, vốn phổ biến trong một số mô hình tổng quát.

FatFormer [29]. Nó sử dụng CLIP và giới thiệu các bộ điều hợp nhận biết giả mạo để trích xuất các dấu vết điều tra từ cả miền không gian và miền tần số. Phương pháp đề xuất cơ chế căn chỉnh theo ngôn ngữ để giám sát quá trình và đảm bảo sự liên kết giữa hình ảnh và văn bản.

Nhanh hơn ThanLies [23]. Phương pháp này sử dụng Mạng nơ-ron nhị phân cho giai đoạn trích xuất các đặc điểm và bộ phân loại tuyến tính để phát hiện. Ngoài hình ảnh, mô hình còn có hai kênh đầu vào bổ sung: cường độ Biến đổi Fourier nhanh và hình ảnh Mẫu nhị phân cục bộ. Chúng tôi báo cáo kết quả bằng cách sử dụng xương sống BNext-M không đóng băng.

RINE [22]. Nó sử dụng các tính năng được trích xuất từ các khối trung gian của bộ mã hóa CLIP và một mô-đun có thể huấn luyện bổ sung để tính đến ảnh hưởng của từng khối đến quyết định cuối cùng.

TRỢ LÝ [48]. Nó tận dụng các tính năng kết hợp được trích xuất từ mô hình Open CLIP dựa trên ConvNeXt và CNN được cung cấp các bản vá được lọc để loại bỏ nội dung ngữ nghĩa và

khai thác các hiện vật cấp thấp.

LaDeDA [6]. Nó là một trình phân loại dựa trên bản vá tận dụng các tính năng hình ảnh cục bộ. Hình ảnh được chia thành nhiều mảng, đối với mỗi mảng, một dự đoán được tính toán và sau đó tính trung bình để có được dự đoán ở cấp độ hình ảnh.

C2P-CLIP [43]. Nó sử dụng chiến lược Thích ứng Xếp hạng Thấp (LoRA) để tinh chỉnh bộ mã hóa hình ảnh của CLIP. Hơn nữa, nó dựa vào chiến lược học tập tương phản dựa trên lời nhắc về danh mục.

Mã [3]. CodeE huấn luyện Vision Transformer bằng cách sử dụng tổn thất tương phản tự nhiên như CLIP. Tuy nhiên, trong khi CLIP nhằm mục đích tìm hiểu các tính năng khớp văn bản-hình ảnh thì CoDE lại nhằm đến việc có được một không gian nhúng trong đó hình ảnh thật và giả được phân tách một cách hiệu quả. Chúng tôi báo cáo kết quả bằng cách sử dụng CoDE kết hợp với bộ phân loại tuyến tính.

C. Số liệu hiệu chuẩn

Ở đây chúng tôi cung cấp thêm một số chi tiết về các số liệu hiệu chuẩn được sử dụng trong bài báo. Lỗi hiệu chuẩn dự kiến nhị phân (ECE) được định nghĩa là:


$$ECE = \sum_{m=1}^M \frac{|B_m|}{N} |\text{prob}(B_m) - \text{pred}(B_m)| \quad (1)$$

where N is the number of samples of the test-set, M is the number of bins, and B_m is the set of samples whose predictions fall into the m -th bin, with $|B_m|$ its cardinality. $\text{prob}(B_m)$ and $\text{pred}(B_m)$ are the actual probability and the average predicted probability of the target class in that bin, respectively. In case of unbalanced test-set, we weigh the contribution of each sample in the average to re-balance the relevance between two classes. We used $M = 15$ bins.

Khả năng ghi nhận ký âm cân bằng (NLL) được định nghĩa là:

$$NLL = -\frac{0.5}{|S_0|} \sum_{i \in S_0} \log p_i(0) - \frac{0.5}{|S_1|} \sum_{i \in S_1} \log p_i(1) \quad (2)$$

where S_0 and S_1 are the set of samples of non-target and target class, respectively, while $p_i(0)$ and $p_i(1)$ are the predicted probabilities of the two classes for the i -th input sam- ple.



Hình 10. Hiệu suất SoTA được đánh giá theo AUC và Độ chính xác cân bằng trên các trình tạo Midjourney, SDXL và DALL-E 3 từ các bộ dữ liệu khác nhau.

D. Cắt bỏ bổ sung

Trong Phần này, chúng tôi điều tra sâu hơn về ảnh hưởng của tập dữ liệu huấn luyện của chúng tôi. Chúng tôi đào tạo mạng của mình dựa trên tập dữ liệu Phát hiện Deepfake do Khuếch tán tạo (D³) mới nhất [3], gồm khoảng 8 triệu hình ảnh tổng hợp (từ 256×256 đến 1024×1024) từ các trình tạo SD 1.4, SD 2.1, SDXL và DeepFloyd IF. Hình ảnh được tạo bằng cách sử dụng lời nhắc lấy từ mô tả nguồn thực của LAION (tạo theo hướng văn bản). Từ Tab. Như được hiển thị trong Hình 8, chúng ta có thể nhận thấy rằng mặc dù AUC tương tự nhau nhưng có sự gia tăng đáng kể về độ chính xác cân bằng (87,5 so với 95,2) và giảm về cả NLL (0,31 so với 0,14) và ECE (0,13 so với 0,04). Điều này xác nhận rằng mô hình đào tạo của chúng tôi cho phép hiệu chỉnh tốt hơn và cải thiện khả năng khái quát hóa.

E. Phân tích khái quát hóa bổ sung

Trong Phần này, chúng tôi tiến hành các thử nghiệm sâu hơn để xác nhận rằng phương pháp của chúng tôi có thể khái quát hóa tốt hơn các phương pháp khác và thu được kết quả ít sai lệch hơn. Chúng tôi cũng trình bày chi tiết các kết quả và hiển thị hiệu suất trên từng trình tạo tổng hợp cho bộ dữ liệu GenImage và FakeBench.

Đánh giá trên cùng một máy phát điện từ các bộ dữ liệu khác nhau. Ở đây, chúng tôi mở rộng thêm phân tích được thực hiện trong Hình 2, trong đó chúng tôi đã chỉ ra rằng một số máy dò đạt được hiệu suất khác nhau trên cùng một trình tạo khi hình ảnh được chụp từ hai bộ dữ liệu khác nhau. Hành vi khó hiểu này

gợi ý khả năng các phương pháp này dựa vào các sai lệch dữ liệu tinh tế bên cạnh các dấu vết thực sự do trình tạo tổng hợp để lại. Trong Hình 10, chúng tôi mở rộng phân tích này cho tất cả các phương pháp SoTA được mô tả trong Phần. B. Cụ thể hơn, chúng tôi phân tích hiệu suất về mặt AUC và độ chính xác cân bằng trên ba trình tạo tổng hợp: Midjourney, SDXL và DALL-E 3 đến từ ba bộ dữ liệu khác nhau PolarDiffShield [25], Synthbuster [2] và FakeInversion [7]. Như đã nói trước đây, đối với một số phương pháp, hiệu suất không nhất quán trên cùng một trình tạo và có thể thay đổi thậm chí 20% từ tập dữ liệu này sang tập dữ liệu khác. Ngoài ra, đối với một số phương pháp, AUC là khoảng 50%, tương ứng với lựa chọn ngẫu nhiên, hoặc thậm chí dưới 50%, điều đó có nghĩa là máy dò có xu hướng đảo ngược nhãn giữa thật và giả.

Đánh giá trên các máy phát điện tổng hợp khác nhau. Chúng tôi tiến hành phân tích chi tiết hơn về kết quả trên GenImage (không thiên vị), trong đó các hình ảnh giả mạo đã được nén JPEG, tương tự như hình ảnh thật, để ngăn các trình phát hiện khai thác các thành phần giả nén. Chúng tôi cũng xem xét FakeBench [26], bao gồm 3.000 hình ảnh thật và 3.000 hình ảnh giả được tạo bởi 10 mô hình khác nhau. Các bộ dữ liệu này bao gồm cả hình ảnh tổng hợp dựa trên GAN và Khuếch tán, cho phép chúng tôi hiểu rõ hơn về khả năng khái quát hóa phương pháp của chúng tôi cho các kiến trúc khác nhau. Kết quả được trình bày trong Tab. 9 và Tab. 10. Chúng tôi lưu ý rằng phương pháp của chúng tôi thu được kết quả rất tốt một cách nhất quán trên hầu hết các máy phát điện, trong khi các phương pháp khác, chẳng hạn như DMID, Uni-

AUC↑/bAcc↑	GenImage (unbiased)								
	BigGAN	VQDM	ADM	GLIDE	SD 1.4	SD 1.5	Midjourney	Wukong	AVG
CNNDetect	70.9 / 58.4	63.4 / 51.2	51.8 / 49.9	59.4 / 50.7	65.1 / 50.1	66.4 / 49.9	79.3 / 50.1	62.6 / 50.2	64.8 / 51.3
DMID	74.6 / 52.3	97.6 / 75.1	78.5 / 51.3	94.9 / 56.6	100. / 99.9	100. / 99.8	100. / 97.4	100. / 99.6	93.2 / 79.0
LGrad	18.7 / 28.9	23.9 / 30.8	24.6 / 30.5	22.2 / 30.0	50.0 / 49.8	49.2 / 49.1	50.5 / 50.6	47.6 / 46.9	35.8 / 39.6
UnivFD	96.7 / 86.1	94.8 / 79.7	85.2 / 64.4	88.8 / 63.9	78.7 / 55.5	78.1 / 56.6	74.0 / 54.2	86.9 / 63.7	85.4 / 65.5
DeFake	72.6 / 64.4	71.1 / 64.4	49.3 / 48.5	87.9 / 80.4	93.3 / 85.1	93.4 / 85.4	87.7 / 79.2	89.8 / 81.8	80.6 / 73.7
DIRE	26.6 / 46.9	35.0 / 47.7	25.3 / 46.7	29.9 / 47.0	41.7 / 47.3	39.8 / 47.3	38.0 / 47.5	45.4 / 47.7	35.2 / 47.3
AntifakePrompt	- / 81.7	- / 81.1	- / 81.6	- / 81.8	- / 77.1	- / 76.6	- / 70.4	- / 77.6	- / 78.5
NPR	56.9 / 56.3	52.3 / 53.9	46.9 / 50.5	42.1 / 48.3	54.3 / 49.4	53.3 / 49.7	42.3 / 47.4	52.4 / 50.2	50.1 / 50.7
FatFormer	88.5 / 80.1	84.5 / 71.5	69.1 / 60.4	78.4 / 65.1	49.8 / 52.0	48.7 / 53.3	46.2 / 51.6	61.6 / 58.1	65.9 / 61.5
FasterThanLies	78.9 / 54.1	86.8 / 76.6	88.6 / 77.2	83.0 / 66.1	97.8 / 92.2	97.9 / 92.3	83.1 / 69.7	95.4 / 88.1	88.9 / 77.0
RINE	99.4 / 88.5	98.4 / 81.4	93.8 / 63.9	98.1 / 74.7	93.9 / 60.5	94.1 / 61.1	86.3 / 52.4	95.7 / 70.0	95.0 / 69.1
AIDE	73.1 / 50.7	78.0 / 51.0	61.2 / 50.1	80.4 / 52.3	98.2 / 74.5	98.5 / 75.9	88.1 / 57.4	95.9 / 69.3	84.2 / 60.2
LaDeDa	93.1 / 80.3	10.8 / 34.8	6.8 / 34.6	8.8 / 34.5	55.6 / 54.8	53.6 / 53.0	51.3 / 52.1	61.6 / 57.7	42.7 / 50.2
C2P-CLIP	97.2 / 87.5	92.2 / 74.1	86.7 / 71.3	93.6 / 74.8	94.4 / 80.5	94.3 / 79.1	76.3 / 55.9	93.1 / 81.0	91.0 / 75.5
CoDE	70.2 / 50.0	66.8 / 56.0	53.7 / 51.9	78.1 / 58.0	99.4 / 96.6	99.2 / 96.5	86.0 / 69.6	99.1 / 95.0	81.6 / 71.7
B-Free (ours)	94.1 / 68.7	97.0 / 88.7	93.0 / 79.8	95.8 / 85.3	100. / 98.8	100. / 98.8	99.2 / 95.7	100. / 99.0	97.4 / 89.3

Bảng 9. Hiệu suất trên mỗi trình tạo có trong bộ dữ liệu GenImage (không thiên vị) về AUC và Độ chính xác cân bằng. In đậm gạch chân hiệu suất tốt nhất cho mỗi cột với mức chênh lệch 1%.

AUC↑/bAcc↑	FakeBench										
	ProGAN	StyleGAN	FuseDream	VQDM	GLIDE	CogView2	DALL-E 2	DALL-E 3	SD	Midjourney	AVG
CNNDetect	100. / 99.7	98.3 / 75.1	94.8 / 61.1	62.9 / 51.9	62.6 / 50.6	64.9 / 49.7	56.1 / 49.7	58.6 / 49.7	57.2 / 49.7	62.0 / 49.9	71.7 / 58.7
DMID	61.0 / 51.1	80.1 / 52.1	93.1 / 52.4	97.8 / 79.7	94.0 / 63.2	100. / 99.7	94.9 / 55.1	96.7 / 88.9	100. / 99.1	97.3 / 90.7	91.5 / 73.2
LGrad	96.8 / 77.1	82.3 / 72.9	18.9 / 28.4	75.2 / 68.6	41.8 / 43.9	23.7 / 33.6	10.9 / 27.6	30.6 / 35.6	24.7 / 34.1	76.1 / 67.3	48.1 / 48.9
UnivFD	99.9 / 98.6	96.0 / 83.4	99.2 / 96.3	94.6 / 77.3	86.5 / 62.8	84.7 / 63.1	88.0 / 65.9	69.6 / 55.8	76.8 / 56.4	65.5 / 55.6	86.1 / 71.5
DeFake	63.7 / 58.1	73.7 / 66.7	53.8 / 51.0	69.8 / 64.5	81.6 / 74.2	84.7 / 77.2	83.6 / 76.5	81.7 / 74.5	86.4 / 77.3	78.7 / 70.5	75.8 / 69.0
DIRE	90.4 / 89.5	56.6 / 55.4	23.7 / 40.0	91.3 / 89.2	53.2 / 63.7	36.7 / 41.0	44.2 / 43.0	76.6 / 74.5	47.7 / 49.7	83.4 / 81.2	60.4 / 62.7
AntifakePrompt	- / 79.0	- / 78.0	- / 78.6	- / 77.0	- / 78.8	- / 75.8	- / 73.4	- / 74.0	- / 71.6	- / 76.1	- / 76.2
NPR	99.5 / 92.4	78.1 / 68.1	48.7 / 42.7	93.4 / 90.9	67.0 / 65.2	50.3 / 42.7	41.7 / 42.9	46.3 / 44.6	57.5 / 51.4	89.0 / 84.6	67.1 / 62.5
FatFormer	100. / 97.6	99.3 / 97.1	90.7 / 81.8	96.8 / 88.5	74.2 / 69.0	47.1 / 53.3	45.3 / 48.1	52.4 / 49.5	50.4 / 51.0	79.6 / 64.6	73.6 / 70.0
FasterThanLies	87.0 / 80.2	72.4 / 57.7	85.7 / 75.4	54.7 / 45.9	76.9 / 62.5	96.0 / 87.7	92.9 / 85.7	73.6 / 60.6	93.6 / 84.5	67.6 / 57.7	80.0 / 69.8
RINE	100. / 99.6	99.3 / 95.1	99.8 / 96.6	98.8 / 88.6	95.4 / 70.2	86.7 / 59.2	93.0 / 60.9	75.1 / 52.6	85.5 / 55.9	82.2 / 61.1	91.6 / 74.0
AIDE	89.4 / 64.3	89.4 / 70.0	71.7 / 47.3	90.7 / 78.1	79.7 / 68.3	85.5 / 60.0	84.1 / 52.6	88.0 / 61.9	86.0 / 64.6	88.0 / 71.5	85.2 / 63.9
LaDeDa	98.0 / 82.5	94.5 / 82.5	37.2 / 40.5	85.8 / 81.5	52.6 / 57.3	39.4 / 41.6	36.4 / 35.3	49.9 / 45.1	45.3 / 46.1	90.7 / 78.1	63.0 / 59.1
C2P-CLIP	100. / 99.5	99.4 / 98.0	98.2 / 93.0	97.1 / 86.7	91.9 / 76.4	67.3 / 61.7	72.6 / 56.9	74.7 / 55.5	74.9 / 59.9	88.1 / 58.0	86.4 / 74.6
CoDE	64.3 / 52.5	53.0 / 49.5	73.4 / 56.3	78.4 / 61.7	91.6 / 78.0	97.7 / 93.7	93.8 / 82.8	95.8 / 89.2	99.5 / 96.2	89.7 / 76.7	83.7 / 73.7
B-Free (ours)	99.3 / 96.4	97.7 / 88.5	99.3 / 95.2	96.5 / 86.5	95.5 / 87.7	100. / 98.9	98.7 / 94.9	99.9 / 98.7	100. / 98.7	98.0 / 94.5	98.5 / 94.0

Bảng 10. Hiệu suất trên mỗi trình tạo có trong bộ dữ liệu FakeBench về AUC và Độ chính xác cân bằng. In đậm gạch chân hiệu suất tốt nhất cho mỗi cột với mức chênh lệch 1%.

vFD, RINE, FasterThanLies và FatFormer chỉ hoạt động rất tốt về mặt AUC trên một số trình tạo nhất định. Ngoài ra, đối với phương pháp của chúng tôi, khoảng cách giữa AUC và độ chính xác cân bằng được giảm xuống, đảm bảo kết quả đáng tin cậy hơn.


Cuối cùng, chúng tôi đã tạo ra một bộ 2.000 hình ảnh với hai mô hình tự hồi quy [24, 51]. kiến trúc của nó khác biệt đáng kể so với kiến trúc được sử dụng để tạo ra dữ liệu huấn luyện. Trên cả hai mô hình, chúng tôi thu được kết quả tốt với mức trung bình là 99% về AUC và 94,2% về Độ chính xác. Điều này có thể là do sự giống nhau giữa mã thông báo được sử dụng trong các mô hình này và các trình nhúng tiềm ẩn của các mô hình Khuếch tán ổn định.

F. Phân tích độ bền bổ sung

Chúng tôi lặp lại thí nghiệm được báo cáo trong Hình 6 để kiểm tra độ ổn định trong các hoạt động khác nhau và tiến hành so sánh

with SOTA methods. Kết quả được hiển thị trong Hình 11 dưới ba thao tác xử lý hậu kỳ: nén JPEG, thay đổi kích thước và làm mờ. Chúng tôi có thể nhận thấy rằng phương pháp tiếp cận của chúng tôi mạnh mẽ hơn với biên độ lớn so với các phương pháp khác và có thể đảm bảo độ chính xác cân bằng luôn trên 80% ngay cả trong kịch bản khó khăn nhất.

Cuối cùng, chúng tôi điều tra thêm về hiệu suất mạnh mẽ trên FakeInversion [7], nơi hình ảnh thực được lấy từ web. Để hiểu rõ hơn về tác dụng của việc nén và thay đổi kích thước, chúng tôi so sánh hiệu suất khi áp dụng các thao tác đó. Đặc biệt, để mô phỏng việc tải lên mạng xã hội, chúng tôi thay đổi kích thước với hệ số tỷ lệ được lấy mẫu ngẫu nhiên trong khoảng từ 0,7 đến 1 và nén với hệ số chất lượng JPEG trong khoảng từ 70 đến 100. Trong Tab. 11 kết quả cho thấy hiệu suất trên các cơ sở dữ liệu đó giảm đáng kể, ngoại trừ DMID và phương pháp của chúng tôi, mặc dù phương pháp của chúng tôi có số liệu hiệu chỉnh tốt hơn.



Hình 11. Phân tích độ chắc chắn về mặt cân bằng Độ chính xác được thực hiện trên chín bộ tạo Synthbuster theo ba hoạt động xử lý hậu kỳ khác nhau: nén JPEG, thay đổi kích thước và làm mờ. Năm máy dò SoTA hoạt động tốt nhất trên Synthbuster đã được đưa vào phân tích.

	Original		Social network simulation	
	AUC↑/bAcc↑	NLL↓/ECE↓	AUC↑/bAcc↑	NLL↓/ECE↓
CNNDetect	54.3 / 50.9	7.94 / .488	51.8 / 50.1	8.73 / .498
DMID	97.3 / 96.1	0.25 / .041	94.4 / 81.3	0.55 / .182
LGrad	84.4 / 77.2	2.27 / .200	60.2 / 55.4	7.59 / .426
UnivFD	54.9 / 52.8	2.19 / .391	49.7 / 50.0	2.57 / .434
DeFake	69.8 / 63.3	0.95 / .225	69.3 / 62.7	0.98 / .236
DIRE	53.3 / 51.8	13.4 / .360	55.5 / 51.7	13.4 / .358
AntifakePrompt	- / 53.9	- / -	- / 54.8	- / -
NPR	91.6 / 87.0	4.96 / .123	43.3 / 49.9	27.1 / .501
FatFormer	68.2 / 59.7	3.45 / .386	48.7 / 50.4	5.44 / .490
FasterThanLies	49.7 / 48.6	3.64 / .476	51.0 / 49.9	3.13 / .458
RINE	69.6 / 63.6	4.84 / .319	62.4 / 52.9	6.28 / .437
AIDE	85.5 / 76.9	0.54 / .137	67.3 / 56.4	0.93 / .276
LaDeDa	91.7 / 84.7	3.03 / .129	51.9 / 53.1	24.8 / .454
C2P-CLIP	74.1 / 59.6	0.82 / .260	71.9 / 59.0	0.89 / .284
CoDE	87.5 / 78.7	0.74 / .143	82.5 / 74.4	0.89 / .173
B-Free (ours)	99.3 / 86.3	0.32 / .144	98.5 / 86.4	0.32 / .131

Bảng 11. Hiệu suất trên tập dữ liệu FakeInversion. Chúng tôi hiện thị kết quả trên tập dữ liệu gốc và trên phiên bản được xử lý sau để mô phỏng việc tải lên mạng xã hội.

Tài liệu tham khảo

- [1] Roberto Amoroso, Davide Morelli, Marcella Cornia, Lorenzo Baraldi, Alberto Del Bimbo và Rita Cucchiara. Cha mẹ và Con cái: Phân biệt Hình ảnh giả sâu đa phương thức với Hình ảnh tự nhiên. *ACM Trans. Máy tính đa phương tiện. Liên lạc. Đơn đăng ký*, 2024. 3
- [2] Quentin Bammey. Synthbuster: Hướng tới việc phát hiện các hình ảnh được tạo ra từ mô hình khuếch tán. *Tạp chí mở về xử lý tín hiệu của IEEE*, 2023. 2, 3, 4, 11
- [3] Lorenzo Baraldi, Federico Cocchi, Marcella Cornia, Lorenzo Baraldi, Alessandro Nicolosi và Rita Cucchiara. Tương phản sự lan truyền Deepfakes thông qua học tập tương phản và sự tương đồng toàn cầu-đa phương. Vào *ECCV*, 2024. 2, 3, 4, 7, 10, 11
- [4] Clark Barrett, Brad Boyd, Elie Bursztein, Nicholas Carlini, Brad Chen, Jihye Choi, Amrita Roy Chowdhury, Mihai Christodorescu, Anupam Datta, Soheil Feizi, và những người khác. Xác định và giảm thiểu rủi ro bảo mật của AI sáng tạo.

Nền tảng và Xu hướng® về Quyền riêng tư và Bảo mật, 6(1):1– 52, 2023. 1

- [5] Giuseppe Cattaneo và Gianluca Roscigno. Một cạm bẫy có thể xảy ra trong phân tích thử nghiệm các thuật toán phát hiện giả mạo. Trong *Hội nghị quốc tế về hệ thống thông tin dựa trên mạng*, 2014. 2
- [6] Bar Cavia, Eliahu Horwitz, Tal Reiss và Yedid Hoshen. Phát hiện deepfake theo thời gian thực trong thế giới thực. *arXiv bản in trước arXiv:2406.09398*, 2024. 4, 7, 10
- [7] George Cazenavette, Avneesh Sud, Thomas Leung và Ben Usman. FakeInversion: Học cách phát hiện hình ảnh từ các mô hình chuyển văn bản thành hình ảnh chưa được nhìn thấy bằng cách đảo ngược quá trình khuếch tán ổn định. Trong *CVPR*, trang 10759–10769, 2024. 2, 3, 4, 7, 11, 12 [8] You-Ming Chang, Chen Yeh, Wei-Chen Chiu và Ning Yu. AntifakePrompt: Các mô hình ngôn ngữ thị giác được điều chỉnh nhanh chóng là công cụ phát hiện hình ảnh giả. *arXiv preprint arXiv:2310.17419*, 2023. 7, 10
- [9] Riccardo Corvi, David Cozzolino, Giovanni Poggi, Koki Nagano và Luisa Verdoliva. Các đặc tính hấp dẫn của hình ảnh tổng hợp: từ mạng lưới đối nghịch tổng hợp đến mô hình khuếch tán. Trong *Hội thảo CVPR*, trang 973–982,
- [10] Riccardo Corvi, Davide Cozzolino, Giada Zingarini, Giovanni Poggi, Koki Nagano và Luisa Verdoliva. Về việc phát hiện các hình ảnh tổng hợp được tạo ra bởi các mô hình khuếch tán. Trong *ICASSP*, trang 1–5, 2023. 3, 4, 6, 7,
- [11] Davide Cozzolino, Giovanni Poggi, Riccardo Corvi, Matthias Nießner và Luisa Verdoliva. Nâng cao khả năng phát hiện hình ảnh do AI tạo ra bằng CLIP. Trong *Hội thảo CVPR*, trang 4356–4366, 2024. 2, 3, 4, 6, 7
- [12] Duc-Tien Dang-Nguyen, Cecilia Pasquini, Valentina Conoter, và Giulia Boato. RAISE: bộ dữ liệu hình ảnh thô để điều tra hình ảnh kỹ thuật số. Trong *ACM MMSys*, trang 219–224. Hiệp hội Máy tính, 2015. 2
- [13] Timothée Darcet, Maxime Oquab, Julien Mairal, and Piotr Bojanowski. Vision Transformers Need Registers. In *ICLR*, 2024. 5, 6, 9
- [14] Jing Dong, Wei Wang và Tieniu Tan. Cơ sở dữ liệu đánh giá phát hiện giả mạo hình ảnh CASIA. Trong *IEEE ChinaSIP*, 2013. 2
- [15] Ricard Durall, Margret Keuper và Janis Keuper. Theo dõi sự phức tạp của bạn: Mạng thần kinh sâu sáng tạo dựa trên CNN không thể tái tạo sự phân bố quang phổ. Trong *CVPR*, trang 7890–7899, 2020. 3
- [16] Tarik Dzanic, Karan Shah và Freddie Witherden. Sự khác biệt về phổ Fourier trong các hình ảnh được tạo ra từ mạng sâu. Trong *NeurIPS*, trang 3022–3032, 2020. 3
- [17] Ziv Epstein, Aaron Hertzmann, et al. Art and the science of generative AI. *Science*, 380(6650):1110–1111, 2023. 1 [18] Diego Gagnaniello, Davide Cozzolino, Francesco Marra, Giovanni Poggi, and Luisa Verdoliva. Are GAN generated images easy to detect? A critical analysis of the state-of-the-art. In *ICME*, pages 1–6, 2021. 2
- [19] Patrick Grommelt, Louis Weiss, Franz-Josef Pfreundt và Janis Keuper. Giả hay JPEG? Tiết lộ những thành kiến thường gặp trong bộ dữ liệu phát hiện hình ảnh được tạo. Trong *Hội thảo ECCV*, 2024. 2, 4

- [20] Yonghyun Jeong, Doyeon Kim, Youngmin Ro, Pyounggeon Kim và Jongwon Choi. Vân tayNet: Dấu vân tay tổng hợp để phát hiện hình ảnh được tạo. Trong *ECCV*, trang 76–94, 2022. 3
- [21] Dimitrios Karageorgiou, Quentin Bammey, Valentin Porcellini, Bertrand Goupil, Denis Teyssou, và Symeon Papadopoulos. Sự phát triển của Hiệu suất Phát hiện trong suốt Vòng đời Trực tuyến của Hình ảnh Tổng hợp. Tại *Hội thảo ECCV*, 2024. 7
- [22] Christos Koutlis và Symeon Papadopoulos. Tận dụng các biểu diễn từ các khối mã hóa trung gian để phát hiện hình ảnh tổng hợp. Trong *ECCV*, trang 394–411, 2024. 2, 3, 6, 7, 10
- [23] Romeo Lanzino, Federico Fontana, Anxhelo Diko, Marco Raoul Marini và Luigi Cinque. Nhanh hơn lời nói dối: Phát hiện deepfake theo thời gian thực bằng cách sử dụng Mạng thần kinh nhị phân. Trong *Hội thảo CVPR*, trang 3771–3780, 2024. 3, 7, 10
- [24] Tianhong Li, Yonglong Tian, He Li, Mingyang Deng, và Kaiming He. Tạo hình ảnh tự động hồi quy mà không cần lượng tử hóa vector. Trong *NeurIPS*, trang 56424–56445, 2024. 12 [25] Yanhao Li, Quentin Bammey, Marina Gardella, Tina Nikoukhah, Jean-Michel Morel, Miguel Colom và Rafael Grompone Von Gioi. MaskSim: Phát hiện hình ảnh tổng hợp bằng phân tích tương tự phổ mặt nạ. Trong *CVPR*, trang 3855–3865, 2024. 11
- [26] Yixuan Li, Xuelin Liu, Xiaoyang Wang, Bu Sung Lee, Shiqi Wang, Anderson Rocha, và Weisi Lin. FakeBench: Thăm dò khả năng phát hiện hình ảnh giả có thể giải thích thông qua các mô hình đa phương thức lớn. *arXiv bản in trước arXiv:2404.13306*, 2024. 11 [27] Li Lin, Neeraj Gupta, Yue Zhang, Hainan Ren, Chun-Hao Liu, Feng Ding, Xin Wang, Xin Li, Luisa Verdoliva và Shu Hu. Phát hiện đa phương tiện được tạo bởi các mô hình AI lớn: Một khảo sát. *arXiv bản in trước arXiv:2204.06125*, 2024. 1 [28] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár và C. Lawrence Zitnick. Microsoft COCO: Các đối tượng phổ biến trong ngữ cảnh. Trong *ECCV*, trang 740–755, 2014. 5
- [29] Huân Liu, Zichang Tan, Chuangchuang Tan, Yunchao Wei, Jingdong Wang và Yao Zhao. Biến áp thích ứng nhận biết giả mạo để phát hiện hình ảnh tổng hợp có thể khái quát hóa. Trong *CVPR*, trang 10770–10780, 2024. 2, 3, 7, 10 [30] Zhuang Liu và Kaiming He. Cuộc chiến của một thập kỷ về xu hướng tập dữ liệu: Chúng ta đã ở đó chưa? Vào *ICLR*, 2025. 2
- [31] Sara Mandelli, Paolo Bestagini và Stefano Tubaro. Khi dấu vết tổng hợp ẩn nội dung thực: Phân tích hoạt động rửa hình ảnh khuếch tán ổn định. Trong *WIFS*, trang 1–6, 2024. 3 [32] Francesco Marra, Diego Gragnaniello, Luisa Verdoliva và Giovanni Poggi. GAN có để lại dấu vân tay nhân tạo không? Trong *MIPR*, trang 506–511, 2019. 2
- [33] Utkarsh Ojha, Yuheng Li và Yong Jae Lee. Hướng tới các máy phát hiện hình ảnh giả phổ quát có thể khái quát hóa trên các mô hình tổng quát. Trong *CVPR*, trang 24480–24489, 2023. 1, 2, 3, 4, 6, 7, 9
- [34] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafranec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. DINOv2: Học các tính năng trực quan mạnh mẽ mà không cần giám sát. *Giao dịch trên Tạp chí Nghiên cứu Học máy*, 2024. 5, 6, 9
- [35] Mahdi Pakdaman Naeini, Gregory Cooper, và Milos Hauskrecht. Đạt được các xác suất được hiệu chỉnh tốt bằng cách sử dụng Bayesian Binning. *AAAI*, 29(1), 2015. 4
- [36] Joaquin Quiñero-Candela, Carl Edward Rasmussen, Fabian Sinz, Olivier Bousquet và Bernhard Schölkopf. Đánh giá thách thức về độ không chắc chắn dự đoán. Trong *Hội thảo về Thứ bậc Học máy*, trang 1–27, 2006. 4 [37] Alec Radford, JongWook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Học các mô hình trực quan có thể chuyển đổi từ giám sát ngôn ngữ tự nhiên. Trong *ICML*, trang 8748–8763, 2021. 1, 6 [38] Anirudh Sundara Rajan, Utkarsh Ojha, Jedidiah Schloesser và Yong Jae Lee. Về hiệu quả của việc căn chỉnh tập dữ liệu để phát hiện hình ảnh giả. *arXiv preprint arXiv:2410.11835*, 2024. 2, 3
- [39] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser và Björn Ommer. Khuếch tán ổn định. <https://github.com/On-diffusion-AI/on-diffusion-kv>, 2022. 5
- [40] Zeyang Sha, Zheng Li, Ning Yu và Yang Zhang. DE-FAKE: Phát hiện và xác định hình ảnh giả mạo được tạo ra bởi các mô hình tạo văn bản thành hình ảnh. Trong *ACM SIGSAC*, trang 3418–3432, 2023. 3, 7, 10
- [41] Chuangchuang Tan, Yao Zhao, Shikui Wei, Guanhua Gu và Yunchao Wei. Tìm hiểu về Độ dốc: Biểu diễn dữ kiện giả tổng quát để phát hiện hình ảnh do GAN tạo. Trong *CVPR*, trang 12105–12114, 2023. 3, 7, 9 [42] Chuangchuang Tan, Huân Liu, Yao Zhao, Shikui Wei, Guanhua Gu, Ping Liu và Yunchao Wei. Xem xét lại các hoạt động lấy mẫu nâng cao trong Generative Network dựa trên CNN để phát hiện deepfake có thể khái quát hóa. Trong *CVPR*, 2024. 7, 10 [43] Chuangchuang Tan, Renshuai Tao, Huân Liu, Guanhua Gu, Baoyuan Wu, Yao Zhao và Yunchao Wei. C2P- CLIP: Đưa lời nhắc chung về danh mục vào CLIP để nâng cao tính khái quát hóa trong phát hiện Deepfake. *arXiv preprint arXiv:2408.09647*, 2024. 3, 7, 10
- [44] Diangarti Tariang, Riccardo Corvi, Davide Cozzolino, Giovanni Poggi, Koki Nagano, and Luisa Verdoliva. Synthetic Image Verification in the Era of Generative AI: What Works and What Isn't There Yet. *IEEE Security & Privacy*, 22: 37–49, 2024. 1, 4
- [45] Antonio Torralba và Alexei A. Efros. Cái nhìn khách quan về sự thiên vị của tập dữ liệu. Trong *CVPR*, 2011. 2
- [46] Sheng-Yu Wang, Oliver Wang, Richard Zhang, Andrew Owens và Alexei A Efros. Hiện tại, những hình ảnh do CNN tạo ra dễ dàng được phát hiện một cách đáng ngạc nhiên. Trong *CVPR*, trang 8695–8704, 2020. 3, 4, 5, 6, 7, 9, 10
- [47] Zhendong Wang, Jianmin Bao, Wengang Zhou, Weilun Wang, Hezhen Hu, Hong Chen, và Houqiang Li. DIRE để phát hiện hình ảnh do khuếch tán. Trong *ICCV*, trang 22445–22455, 2023. 3, 7, 10
- [48] Shilin Yan, Ouxiang Li, Jiayin Cai, Yanbin Hao, Xiaolong Jiang, Yao Hu và Weidi Xie. Kiểm tra độ chính xác để phát hiện hình ảnh do AI tạo. Vào *ICLR*, 2025. 7, 10

- [49] Xingyi Yang, Daquan Chu, Jiashi Feng, và Xinchao Wang. Mô hình xác suất khuếch tán Made Slim. Trong *CVPR*, trang 22552–22562, 2023. 3
- [50] Ning Yu, Larry S Davis, và Mario Fritz. Gán hình ảnh giả cho GAN: Tìm hiểu và phân tích đầu vôn tay GAN. Trong *ICCV*, trang 7556–7566, 2019. 2
- [51] Qihang Yu, Ju He, Xueqing Deng, Xiaohui Shen và Liang-Chieh Chen. Tạo hình ảnh tự động hồi quy ngẫu nhiên. *arXiv bản in trước arXiv:2411.00776*, 2024. 12
- [52] Sangdoon Yun, Dongyoon Han, Seong Joon Oh, Sanghyuk Chun, Junsuk Choe và Youngjoon Yoo. CutMix: Chiến lược chính quy hóa để huấn luyện các bộ phân loại mạnh mẽ với các tính năng có thể bản địa hóa. Trong *ICCV*, trang 6023–6032, 2019. 6 [53] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov và Lucas Beyer. Mất sigmoid để đào tạo trước hình ảnh ngôn ngữ. Trong *ICCV*, trang 11975–11986, 2023. 6
- [54] Fangneng Zhan, Yingchen Yu, Rongliang Wu, Jiahui Zhang, Shijian Lu, Lingjie Liu, Adam Kortylewski, Christian Theobalt và Eric Xing. Tổng hợp và chỉnh sửa hình ảnh đa phương thức: Kỹ nguyên AI sáng tạo. *IEEE TPAMI*, 45(12): 15098–15119, 2021. 1
- [55] Hongyi Zhang, Moustapha Cisse, Yann N. Dauphin, và David Lopez-Paz. hỗn hợp: Ngoài việc giảm thiểu rủi ro theo kinh nghiệm. Trong *ICLR*, 2018. 6
- [56] Xu Zhang, Svebor Karaman, và Shih-Fu Chang. Phát hiện và mô phỏng các hiện vật trong hình ảnh giả mạo GAN. Vào *WIFS*, 2019. 3
- [57] Mingjian Zhu, Hanting Chen, Qiangyu Yan, Xudong Huang, Guanyu Lin, Wei Li, Zhijun Tu, Hailin Hu, Jie Hu và Yunhe Wang. GenImage: Điểm chuẩn quy mô hàng triệu để phát hiện hình ảnh do AI tạo ra. *NeurIPS*, 36:77771–77782, 2023. 4